

杭州电子科技大学

硕士学位论文

题 目：面向图像处理技术的卡尔曼滤波方法

研 究 生 付仁杰

专 业 控制工程

指导教师 文成林 教授 徐晓滨 教授

完成日期 2021 年 3 月 16 日

杭州电子科技大学硕士学位论文

面向图像处理技术的卡尔曼滤波方法

研 究 生：付仁杰

指导教师：文成林 教授 徐晓滨 教授

2021 年 3 月

Dissertation Submitted to Hangzhou Dianzi
University for the Degree of Master

**Kalman Filter Method for Image
Processing Technology**

Candidate: Fu Renjie

Supervisor: Prof. Wen Chenglin Prof. Xu Xiaobin

March, 2021

杭州电子科技大学

学位论文原创性声明和使用授权说明

原创性声明

本人郑重声明： 所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品或成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

论文作者签名：付仁杰

日期：2021 年 3 月 23 日

学位论文使用授权说明

本人完全了解杭州电子科技大学关于保留和使用学位论文的规定，即：研究生在校攻读学位期间论文工作的知识产权单位属杭州电子科技大学。本人保证毕业离校后，发表论文或使用论文工作成果时署单位名称仍然为杭州电子科技大学。学校有权保留送交论文的复印件，允许查阅和借阅论文；学校可以公布论文的全部或部分内容，可以允许采用影印、缩印或其它复制手段保存论文。（保密论文在解密后遵守此规定）

论文作者签名：付仁杰

日期：2021 年 3 月 23 日

指导教师签名：王峰
张明

日期：2021 年 3 月 23 日

摘 要

卡尔曼滤波器是一种广泛应用于复杂系统的状态重构与参数估计的自适应滤波器。除了在复杂系统的状态估计上有很好的应用外,在高噪声污染图像的噪声抑制,扭曲图像的恢复与重构等方面也有很好的应用。为此,本项目开展基于卡尔曼滤波的图像预处理方法研究,通过增强图像的质量,有效提高对目标的识别精度。本项目的工作如下:

(1) 提出基于序列跟踪目标图像恢复的卡尔曼滤波方法,其创新点在于,当污染图像的噪声过大或图像发生了形变时,单张受损图像的滤波已无法达到任务对恢复图像的质量需求,这时通过卡尔曼滤波器对顺序得到的多幅受损图像的信息,进行互补以解决问题。最后对受损图像发生非线性变换的情况进行展望与准备。

(2) 提出基于神经网络水样图像水质评价的卡尔曼滤波方法,其创新点在于,将卡尔曼滤波器可以对模糊神经网络进行参数优化的特点,运用在水质评价的应用工程领域。首先由卷积神经网络与模糊神经网络构建分布式神经网络,输入采样水的数字图像得到其各项指标,再使用模糊神经网络分析指标进行水质监测评分,通过卡尔曼滤波器对该模糊神经网络进行参数优化,可获得更准确的水质监测评分。

(3) 提出基于线性回归人脸识别的卡尔曼滤波方法,阐述基于线性回归的人脸识别方法,通过卡尔曼滤波器分次输入线性回归的参数,最优估计分类模型重构待识别人脸的权重,无需常规的图像特征提取流程,依然能够获得可观的人脸识别正确率,将该方法用于抑制噪声的图像增强,可以有效提高人脸识别的精度。

关键词: 卡尔曼滤波, 图像恢复, 模糊神经网络, 线性回归, 模式识别

ABSTRACT

Kalman filter is an adaptive filter widely used in state reconstruction and parameter estimation of complex systems. In addition to its good application in state estimation of complex systems, it also has good applications in the noise suppression of high-noise polluted images, and the restoration and reconstruction of distorted images. To this end, this project carried out research on image preprocessing methods based on Kalman filtering, which effectively improved the accuracy of target recognition by enhancing the quality of the image. The work of this project is as follows

(1) A Kalman filtering method based on restoration of the sequential tracking target image is proposed. When the noise of the contaminated image is too large or the image is deformed, because the filtering of a single damaged image cannot meet the task's demand for image quality, Kalman filtering would be performed in complementation and redundancy on the information of multiple damaged images obtained sequentially to solve the problem, and prepares for the non-linear transformation of the damaged image.

(2) A Kalman filter method based on fuzzy neural network for water quality evaluation is proposed. In the application engineering field of water quality monitoring, the distributed neural network proposed is constructed by convolutional neural network and fuzzy neural network. The digital image of sampled water is input to obtain its various indicators, and then used Fuzzy neural network to analysis indicators for the monitoring and scoring of water quality. The distributed parameters of the fuzzy neural network are optimized by Kalman filter to obtain better pattern recognition accuracy.

(3) A Kalman filter method based on linear regression for face recognition is proposed. The face recognition method based on linear regression is described. The linear regression parameters are input into the Kalman filter in stages, and the classification model is optimally estimated to reconstruct the weight of the face to be recognized. Without the conventional image feature extraction process, a considerable accuracy of face recognition can still be obtained. This method can be used to suppress noise in image enhancement, which can effectively improve the accuracy of face recognition.

Keywords: Kalman filter, image restoration, fuzzy neural network, linear regression, pattern recognition

目 录

摘 要.....	I
ABSTRACT	II
目 录.....	III
第 1 章 绪 论.....	1
1.1 研究背景及意义.....	1
1.2 亟待解决的问题.....	2
1.3 主要研究内容与安排.....	3
第 2 章 基础知识.....	4
2.1 卡尔曼滤波.....	4
2.2 扩展卡尔曼滤波.....	5
2.3 无迹卡尔曼滤波.....	7
2.4 模糊神经网络.....	9
2.4.1 模糊数学介绍.....	9
2.4.2 T-S 模糊模型.....	9
2.4.3 T-S 模糊神经网络.....	10
2.5 线性组合.....	10
第 3 章 基于序列跟踪目标图像恢复的卡尔曼滤波方法.....	12
3.1 引言.....	12
3.2 目标序列跟踪图像观测系统模型.....	13
3.3 常用滤波方法介绍.....	13
3.3.1 中值滤波.....	13
3.3.2 均值滤波.....	14
3.3.3 指数滤波.....	15
3.3.4 窗口滤波.....	16
3.3.5 维纳滤波.....	16
3.4 基于大数定律的序列图像融合方法.....	17
3.5 基于卡尔曼滤波的图像恢复方法.....	17
3.5.1 卡尔曼方程组的矩阵形式描述.....	17
3.5.2 卡尔曼方程组的列向量形式描述.....	18
3.5.3 目标序列观测图像融合的卡尔曼滤波方法.....	18
3.6 仿真实验.....	20
3.6.1 数据来源及评价方法.....	20

3.6.2 基于大数定律的序列图像融合方法仿真.....	20
3.6.3 基于卡尔曼滤波的图像恢复方法仿真一.....	22
3.6.4 基于卡尔曼滤波的图像恢复方法仿真二.....	24
3.7 总结分析.....	25
第 4 章 基于神经网络水样图像水质评价的卡尔曼滤波方法.....	27
4.1 引言.....	27
4.2 模糊神经网络结构.....	28
4.3 基于模糊神经网络的卡尔曼滤波方法.....	29
4.3.1 模糊规则的产生规则.....	29
4.3.2 模糊神经网络的参数调整.....	31
4.3.3 模糊神经网络的分布式调整.....	32
4.3.4 模糊规则的新增加策略.....	33
4.4 仿真实验.....	33
4.5 总结与分析.....	36
第 5 章 基于线性回归人脸识别的卡尔曼滤波方法.....	37
5.1 引言.....	37
5.2 基于线性回归的人脸识别方法.....	38
5.3 基于线性回归人脸识别的卡尔曼滤波方法.....	38
5.3.1 卡尔曼滤波方法建模.....	38
5.3.2 卡尔曼滤波方法描述.....	39
5.4 仿真实验.....	41
5.5 总结与分析.....	43
第 6 章 总结与展望.....	45
6.1 工作总结.....	45
6.2 未来展望.....	46
致 谢.....	47
参考文献.....	48

第 1 章 绪 论

1.1 研究背景

大约从 60 年代开始,得益于计算机等一系列先进技术的迅猛发展,图像处理技术变得日臻成熟,其应用领域也逐步扩大。1970 年,美国依托于其在技术方面的强大优势,尝试通过图像恢复技术对其拍摄到的月球表面照片进行规范专业地处理,解决了数模转换带来的噪声问题,提高了图像质量,取得了较好的效果。自上世纪 80 年代起,随着人工智能技术强势抬头和各国政府的高度重视,图像处理技术取得了长足进展。1982 年,对于通过卫星拍摄的遥感图像,有研究人员尝试通过图像增强技术等进行细致规范地处理,同时,将其处理结果灵活合理地应用于多个行业及领域,比如作物产量估算等,取得了不错的效果。1985 年,英国著名科研人员豪斯菲尔德在进行不懈探索和深入研究后,成功研发出了全球首台以图像重构技术为基础的 X 射线脑断层扫描仪,正是凭借着此成就荣获诺贝尔奖。90 年代左右,伴随着大规模集成电路的日臻完善及广泛应用,包括图像压缩技术等在内的一系列图像处理技术取得了质的改进^[1]。无论是在理论分析领域,还是在实践应用层面,图像处理技术均取得了重大突破,在各种新的技术领域都逐渐成熟,其应用领域进一步扩大。21 世纪正如海德格尔预言的是“世界图像时代”,截止到现在,图像处理技术已构建起了一套完善严谨、规范合理的技术体系,在医学、交通等多个方面得到大力推广和积极应用^[2]。

图像处理技术可大体分为两种:一种是模拟图像处理,另一种是数字图像处理,即我们通常所讲的计算机图像处理^[3]。其优势突出,主要表现为适应能力强、精准性良好等。通常,只要图像处理的程序或算法被更改,图像处理的内容也会相应地变化。数字图像处理是一个较为复杂的过程,主要涉及到图像增强、图像重构、图像编码等一系列重要技术^[4]。图像处理科学的发展与进步离不开众多的数学与计算机图形学的知识,图像处理的相关学科知识也会促进其发展,简而言之,图像处理科学是一门涉及多门学科门类的应用科学。

在数字图像处理中,当图像被输入到计算机时,由于数模转换、有损压缩、环境噪声等现实因素的影响,常导致数字图像质量变差,这样的受损图像难以直接应用,无法满足任务对图像质量的需求^[5]。旨在有条不紊地完成数字图像处理,在正式处理之前,往往需要选取合适的方法对数字图像进行科学合理地预处理,其主要目的在于滤除噪声、提高分辨率等。在图像预处理的过程中,主要涉及到如下流程,即标准化输入图像信息、修正图像,对受损图像进行原始图像复原的图像恢复,对图像进行边缘增强、目标跟踪使其易于人眼观察与计算机处理的图像增强等^[6]。其中通过滤除噪

声对受损图像进行原始图像复原的部分常被称为图像滤波，图像滤波的目的主要有两个：其一是满足计算机图像处理任务有关图像精度的要求，需要对数字图像在数模转换等显示因素下混入的噪声进行消除；其二是能够提取数字图像的特征作为特征识别模型以进行模式识别。图像过滤也有两个要求：其一是受损图像经过图像滤波后具有良好清晰的视觉效果；其二是数字图像的重要信息（如图像轮廓和边缘）不会损坏。图像滤波方法比较丰富多样，比如有基于小波理论的图像滤波与基于卡尔曼滤波的图像滤波等。

1.2 研究现状

在 60 年代初期，卡尔曼等学者在借鉴前人研究成果的基础上，通过孜孜不倦的精神成功发现了卡尔曼滤波，其作用理念是通过线性状态空间清晰准确地描述待处理信号及甄别出来的噪声，从而实时准确地了解系统当前状况。卡尔曼认为其研究成果对阿波罗计划进行科学合理地航迹预测大有裨益，随着滤波器性能、功能的不断完善，其价值逐步受到人们的关注与认可，并且被人们灵活合理地应用于阿波罗导航电脑之中^[7]。自从引入卡尔曼滤波以来，它已在智能电控、雷达领域、污染治理、数模通信、自动控制、航天领域等众多领域大放异彩^[8]。例如，周立波在 2012 年提出了基于卡尔曼滤波 SVM 图像鉴别方法，研究如何区分自然图像和计算机图形判别图像问题。由于人眼难以判别真伪图像，针对传统的图像鉴别方法由于参数的设置而造成识别准确率低，从而无法准确的区分自然图像和计算机图形，提出了一种卡尔曼滤波和支持向量机分类算法相结合的高性能图像真伪鉴别方法。同年，邹丽霞提出一种视频图像改进卡尔曼滤波定位技术，针对处理数据大、要求高的动态视频图像，使用卡尔曼滤波的方法跟踪视频图像。李卓在 2016 年提出基于卡尔曼滤波初始化的图像恢复，针对图像恢复时卡尔曼滤波初始化是随机确定的问题，提出了一种基于噪声参数估计的卡尔曼滤波初始化方法。李占利在 2019 年提出基于卡尔曼滤波的 SAR 图像边缘检测方法，针对传统 Canny 边缘检测算法对合成孔径雷达(SAR)图像的相干斑噪声抑制程度太高,导致大量边缘的真实信息丢失问题,提出一种新型 Canny 算子边缘检测算法。

上述的卡尔曼滤波在图像处理方面的应用是本文的基石，但是只将卡尔曼滤波视作图像处理技术栈里一种优秀滤波算法的想法未免有些局限。广泛来看，卡尔曼滤波是一种广泛应用于信息处理与参数估计场景的自回归滤波器^[9]。需要对实际场景进行系统建模，结合已获取的观测值以及系统动态方程，就能够在进行一系列严谨规范地处理后得到系统状态的最佳预测值。由此，卡尔曼滤波可被应用于更多的需要参数优化的场景，如同本文将卡尔曼滤波器应用于模糊神经网络中的网络参数辨识，亦是卡尔曼滤波器应用于线性回归中的回归向量的最优估计。针对需要非线性建模的场景，卡尔曼滤波器融合了多种不同的解决策略，所以，其在工程领域的应用还有巨大的潜力^[10]。

1.3 亟待解决的问题

本文探讨卡尔曼滤波器在工程领域里信息处理与参数估计的能力。其一是针对当污染图像的噪声过大或图像发生了形变时，单张受损图像的滤波无法达到任务对恢复图像质量需求的场景下，如何通过卡尔曼滤波器对多幅受损图像的信息进行互补与冗余以解决问题。其二是在人脸识别领域，通过卡尔曼滤波器改进基于线性回归的人脸识别方法，通过卡尔曼滤波器分次输入线性回归的参数，最优估计分类模型重构待识别人脸的权重，无需常规的图像特征提取流程，依然能够获得可观的人脸识别正确率。其三是在水质监测这种应用工程领域，通过卷积神经网络与模糊神经网络组成的分布式网络，通过采样水的数字图像分析其各项指标，再通过模糊神经网络进行水质监测评分，通过卡尔曼滤波器对该模糊神经网络的分布式参数优化，可获得更优的模式识别准确率。

1.4 主要研究内容与安排

第1章，绪论。首先针对本文的研究背景和意义进行介绍，依次叙述了图像处理的发展轨迹、数字图像处理的常见手段、数字图像滤波的意义、卡尔曼滤波作为数字图像滤波的常用算法及对卡尔曼滤波在工程领域应用潜力的探讨。

第2章，基础知识。

第3章，基于序列跟踪目标图像恢复的卡尔曼滤波方法，针对当污染图像的噪声过大或图像发生了形变时，单张受损图像的滤波无法达到任务对恢复图像的质量需求的场景下，通过卡尔曼滤波器对多幅受损图像的信息进行互补与冗余以解决问题，并对受损图像发生非线性变换的情况进行展望与准备。

第4章，基于神经网络水样图像水质评价的卡尔曼滤波方法，在水质监测这种应用工程领域，通过卷积神经网络与模糊神经网络组成的分布式网络，通过采样水的数字图像分析其各项指标，再通过模糊神经网络进行水质监测评分，通过卡尔曼滤波器对该模糊神经网络的分布式参数优化，可获得更优的模式识别准确率，而这即表示卡尔曼滤波能够和人工智能神经网络之间高效融合、协同合作，共同发挥作用。

第5章，基于线性回归人脸识别的卡尔曼滤波方法，在当前炙手可热的人脸识别领域，通过线性回归与卡尔曼滤波器的巧妙结合，无需常规的图像特征提取流程，依然能够获得可观的人脸识别正确率，如果引入图像增强与图像压缩，则具有快速人脸识别的潜力。

第6章，总结和展望。在对本文主要研究内容及研究成果进行梳理及简要说明的前提下，对本文不足进行客观揭示，并对未来的工作做出分析和评判。

第 2 章 基础知识

2.1 卡尔曼滤波

考虑用如下状态空间模型描述的动态模型

$$X(k+1) = AX(k) + BW(k) \quad (2.1)$$

$$Y(k) = HX(k) + V(k) \quad (2.2)$$

上式中, 式(2.1)为动态模型方程组中的状态方程, $X(k) \in R^n$ 为动态模型里第 k 个时刻的目标状态, 其当前时刻对应的状态转移矩阵可以定义为 A , $W(k) \in R^r$ 为动态模型里第 k 个时刻预设分布的环境噪声, 其当前时刻对应的驱动矩阵可以定义为 B ; 式(2.1)为动态模型方程组中的观测方程, $Y(k) \in R^m$ 为动态模型里第 k 个时刻目标状态的观测结果, 其当前时刻对应的观测矩阵可以定义为 H , 动态模型里第 k 个时刻观测结果需要预设分布其观测噪声 $V(k) \in R^m$ 。

假设 1: 动态模型里第 k 个时刻预设分布的环境噪声 $W(k)$ 一般设置为高斯白噪声, 其方差为 Q , 均值为 0; 动态模型里第 k 个时刻预设分布的观测噪声 $V(k)$ 通常也是高斯白噪声, 其方差定义为 R , 均值为 0, 环境噪声 $W(k)$ 与观测噪声 $V(k)$ 是互不相关的高斯白噪声。 $EW(k) = 0, EV(k) = 0, EW(k)W^T(j) = Q\delta_{kk}, EV(k)V^T(j) = R\delta_{kj}, W(k)$ 和 $V(k)$ 互不相关, 因此有 $E[W(k)V^T(j)] = 0, \forall k, j$, 其中 $\delta_{kk} = 1, \delta_{kj} = 0, \forall$ 表示“任意”。

假设 2: 初始状态 $X(0)$ 不相关于 $W(k)$ 和 $V(k)$,

$$E[X(0)] = \mu_0 \quad (2.3)$$

$$E[(X(0) - \mu_0)(X(0) - \mu_0)^T] = P_0 \quad (2.4)$$

以前 k 个时刻的目标状态的观测值 $\{Y(1), Y(2), \dots, Y(k)\}$ 为基础, 计算下一时刻的目标状态 $X(j)$ 的最优估计值 $\hat{X}(j|k)$, 即使其协方差最小, 定量分析其协方差是否最小有

$$J = E[(X(j) - \hat{X}(j|k))^T (X(j) - \hat{X}(j|k))] \quad (2.5)$$

对于 $j = k, j > k, j < k$, 分别称 $\hat{X}(j|k)$ 为卡尔曼滤波器、预报器和平滑器。

以射影定理为基础, 可以推导出如下的卡尔曼滤波器

状态一步预测:

$$\hat{X}(k+1|k) = A\hat{X}(k|k) \quad (2.6)$$

状态更新:

$$\hat{X}(k+1|k+1) = \hat{X}(k+1|k) + K(k+1)\varepsilon(k+1) \quad (2.7)$$

$$\varepsilon(k+1) = Y(k+1) - H\hat{X}(k+1|k) \quad (2.8)$$

滤波增益矩阵:

$$K(k+1) = P(k+1|k)H^T[HP(k+1|k)H^T + R]^{-1} \quad (2.9)$$

一步预测协方差阵:

$$P(k+1|k) = AP(k|k)A^T + BQB^T \quad (2.10)$$

协方差阵更新:

$$P(k+1|k+1) = [I_n - K(k+1)H]P(k+1|k) \quad (2.11)$$

$$\hat{X}(0|0) = \mu_0, P(0|0) = P_0 \quad (2.12)$$

式(2.6)-(2.12)中, 卡尔曼滤波显而易见地可以被划分为两个不同信息更新的过程, 即式(2.6)-(2.8)的状态更新过程与式(2.9)-(2.12)的协方差更新过程, 其在卡尔曼滤波器中表现为先进行目标状态的更新, 再进行目标状态估计误差的协方差更新。式(2.6)-(2.8)在卡尔曼滤波器中的作用为, 基于动态模型里第 $k-1$ 个时刻的目标状态估计预测第 k 个时刻的目标状态, 式(2.9)-(2.12)中的协方差大小代表着卡尔曼滤波器最优估计目标状态的效能。卡尔曼滤波器的推导仅仅使用了如目标状态的状态转移矩阵、噪声驱动矩阵、系统噪声方差等动态模型方程组中与目标状态动态特性相关的变量。卡尔曼滤波器中的式(2.6)-(2.8)说明了如何以动态模型里第 $k-1$ 个时刻的目标状态为基础估计预测第 k 个时刻的目标状态, 这是卡尔曼滤波器的随时间推移的目标状态更新过程。式(2.9)-(2.12)是通过上一时刻卡尔曼滤波器估计效能的定量指标即协方差矩阵 $P(k|k-1)$ 、目标状态与观测信息之间的观测矩阵 H 、观测信息的噪声方差 R 及当前时刻的观测信息 $Y(k)$, 计算并更新卡尔曼滤波器这次迭代中最优估计目标状态的性能指标 $P(k+1|k+1)$, 式(2.6)-(2.12)都是以当前时刻的观测信息 $Y(k)$ 为核心, 合理有效地进行动态模型里第 k 个时刻目标状态的最优估计, 因此, 这些方程构成了卡尔曼滤波器随时刻递推的状态更新过程与协方差更新过程。

2.2 扩展卡尔曼滤波

扩展卡尔曼滤波是一种广泛被用于解决非线性系统平滑问题的方法, 其可以很好地将非线性的滤波问题转化为近似的线性滤波问题。扩展卡尔曼滤波在处理非线性系统滤波问题时, 相比卡尔曼滤波需要先将非线性系统中状态方程的状态转移矩阵 $f(*)$ 与观测方程中的观测矩阵 $h(*)$ 对滤波值进行求导, 扩展卡尔曼滤波将非线性的滤波问题转化为近似的线性滤波问题的手段是略去高阶项, 使非线性系统的方程变为只含有一阶项的方程, 以此非线性的滤波问题被转化成了近似的线性滤波问题, 因为扩展卡尔曼滤波是以卡尔曼滤波为基础的, 所以最后仍然需要使用卡尔曼滤波器来完成对目标状态的最优估计。在第 k 个时刻目标状态的一步预测误差 $\tilde{X}_{k,k-1} = X_k - X_{k-1}$ 与第 k 个时刻目标状态的滤波误差 $\tilde{X}_k = X_k - \hat{X}_k$ 较小时, 且非线性系统预设的过程噪声 $W(k)$ 与观测噪声 $V(k)$ 都可以忽略时, 扩展卡尔曼滤波可以不需要提前计算非线性系统方程的解, 这是其的一个优势之处。

离散非线性系统动态方程可以表示为

$$X(k+1) = f[k, X(k)] + G(k)W(k) \quad (2.13)$$

$$Z(k) = h[k, X(k)] + V(k) \quad (2.14)$$

如上述，如果非线性系统预设的过程噪声 $W(k)$ 与观测噪声 $V(k)$ 都可以忽略时，可以通过计算得到非线性系统目标状态的“标称状态”，非线性模型的理论解即是此时离散非线性系统动态方程的解，而非线性系统的实际状态即是此时非线性系统的真实解。

可以通过假定输入量为 0 并提前知晓噪声驱动矩阵 $G(k)$ 来减小计算的负担，并假定系统噪声 $W(k)$ 与观测噪声 $V(k)$ 互不相关，系统噪声 $W(k)$ 的噪声分布为高斯白噪声，其均值为 0，观测噪声 $V(k)$ 的噪声分布也是高斯白噪声，其均值为 0。

首先，扩展卡尔曼滤波将非线性模型的一部分线性化，通过使用那些部分的线性特性。

通过非线性系统状态方程的状态转移矩阵 $f(*)$ 对滤波值进行求导，并略去高阶项，得到只含有一阶项的系统状态方程

$$X(k+1) \approx f[k, \hat{X}(k)] + \frac{\partial f}{\partial \hat{X}(k)} [X(k) - \hat{X}(k)] + G[\hat{X}(k), k]W(k) \quad (2.15)$$

令

$$\frac{\partial f}{\partial \hat{X}(k)} = \frac{\partial f(\hat{X}(k), k)}{\partial \hat{X}(k)} \big|_{\hat{X}(k) = X(k)} = \varphi(k+1|k) \quad (2.16)$$

$$f[\hat{X}(k), k] - \frac{\partial f}{\partial X(k)} \big|_{X(k) = \hat{X}(k)} \hat{X}(k) = \phi(k) \quad (2.17)$$

则状态方程为

$$X(k+1) = \varphi(k+1|k)X(k) + G(k)W(k) + \phi(k) \quad (2.18)$$

初始值为 $X(0) = E[X(0)]$ 。

扩展卡尔曼滤波在获得上一时刻最优估计值 $\hat{X}(k)$ 时，非线性系统的状态方程相比基本的卡尔曼滤波方程会额外增加一个人为预设的条件项 $\phi(k)$ 。

通过非线性的观测方程 $h(*)$ 对非线性系统第 k 时刻的滤波值 $\hat{X}(k)$ 求一阶导可得

$$Z(k) = h[\hat{X}(k|k-1), k] + \frac{\partial h}{\partial \hat{X}(k)} \big|_{\hat{X}(k, k-1)} [X(k) - \hat{X}(k|k-1)] + V(k) \quad (2.19)$$

令

$$\frac{\partial h}{\partial \hat{X}(k)} \big|_{X(k) = \hat{X}(k)} = H(k) \quad (2.20)$$

$$y(k) = h[\hat{X}(k|k-1), k] - \frac{\partial h}{\partial \hat{X}(k)} \big|_{X(k) = \hat{X}(k)} \hat{X}(k|k-1) \quad (2.21)$$

则观测方程为

$$Z(k) = H(k)X(k) + y(k) + V(k) \quad (2.22)$$

因为扩展卡尔曼滤波是基于卡尔曼滤波的，所以最后仍然使用卡尔曼滤波处理线性化后的非线性系统问题

$$H^T(k+1) = f(\hat{X}(k|k)) \quad (2.23)$$

$$P(k+1|k) = \varphi(k+1|k)P(k|k)\varphi^T(k+1|k) + Q(k+1) \quad (2.24)$$

$$K(k+1) = P(k+1|k)H^T(k+1)[H(k+1)P(k+1|k)H^T(k+1) + R(k+1)]^{-1} \quad (2.25)$$

$$\hat{X}(k+1|k+1) = \hat{X}(k+1|k) + K(k+1)[Z(k+1) - h(\hat{X}(k+1|k))] \quad (2.26)$$

$$P(k+1) = [I - K(k+1)H(k+1)]P(k+1|k) \quad (2.27)$$

上式中，滤波初值与滤波初始误差协方差矩阵的初值分别为

$$X(0) = E[X(0)], P(0) = \text{var}[X(0)] \quad (2.28)$$

扩展卡尔曼滤波中线性化系统方程的 f 的 Jacobi 矩阵替换了卡尔曼滤波器中的状态转移矩阵 $\varphi(k+1|k)$ ，扩展卡尔曼滤波中线性化系统方程的 h 的 Jacobi 矩阵替换了卡尔曼滤波器中的观测矩阵 $H(k+1)$ 。

2.3 无迹卡尔曼滤波

现有一个非线性系统，其目标状态随着时刻 k 的推移转变，可以将其建模为一个非线性系统方程组模型，其中含有随机变量序列建模 X 与对应的观测变量矩阵 Z ，随机变量序列建模 X 含有的系统噪声分布为高斯白噪声，观测变量序列 Z 的观测噪声分布为高斯白噪声

$$X(k+1) = f(x(k), W(k)) \quad (2.29)$$

$$Z(k) = h(x(k), V(k)) \quad (2.30)$$

上式中， f 是非线性系统的状态转移矩阵，用于随时刻更新非线性系统的目标状态； h 是目标状态对应的非线性观测函数。

如果假设非线性系统的系统噪声 $W(k)$ 的协方差为 Q ，观测噪声 $V(k)$ 的协方差为 R 。那么无迹卡尔曼滤波可以对该非线性系统目标状态 X 的进行最优估计，其基本步骤如下：

(1) 获取 $2n+1$ 个采样点（即 Sigma 点集），这里的 n 指的是状态的维数

$$\begin{cases} X^{(0)} = \bar{X}, i = 0 \\ X^{(i)} = \bar{X} + (\sqrt{(n+\delta)P})_i, i = 1 \sim n \\ X^{(i)} = \bar{X} - (\sqrt{(n+\delta)P})_i, i = n+1 \sim 2n \end{cases} \quad (2.31)$$

上式中， $(\sqrt{P})^T \sqrt{P} = P, (\sqrt{P})_i$ 表示矩阵方根的第 i 列。

(2) 计算这些采样点对应的权值

$$\begin{cases} w_m^{(0)} = \frac{\delta}{n+\delta} \\ w_c^{(0)} = \frac{\delta}{n+\delta} + (1 - a^2 + \beta) \\ w_m^{(i)} = w_c^{(0)} = \frac{\delta}{2(n+\delta)}, i = 1 \sim 2n \end{cases} \quad (2.32)$$

上式中，变量的上标指 Sigma 点集中的哪个点，变量下标 m 为矩阵，变量下标 c 为协方差，参数 δ 是一个缩放变量，一般用于减小估计的误差

$$\delta = a^2(n+k) - n \quad (2.33)$$

上式中, a 是一个变量, 用于调整 Sigma 点集的分布, k 是人为选择的参数, 其选择的方式一般基于保证矩阵 $(n + \delta)P$ 是半正定的后就可按照经验选择。式(2.32)中人为选择的参数 β 是一个加权参数, 其必须大于等于 0, 因为参数 β 可以将方程中大于等于一阶项的动差包含进来, 所以其可以代替大于等于一阶的项。

因此, 有

$$X^i(k|k) = [\hat{X}(k|k) \quad \hat{X}(k|k) + \sqrt{(n + \delta)P(k|k)} \quad \hat{X}(k|k) - \sqrt{(n + \delta)P(k|k)}] \quad (2.34)$$

(3) 计算 $2n + 1$ 个 Sigma 点集的一步预测, $i = 1, 2, \dots, 2n + 1$

$$X^i(k + 1|k) = f[k, X^i(k|k)] \quad (2.35)$$

(4) 计算非线性系统的目标状态一步预测与其估计误差协方差矩阵一步预测, 它由 $2n + 1$ 个采样点的一步预测值信息融合得到, 信息融合的比例基于式(2.32)得到的权重 $w^{(i)}$ 。仅对上一时刻的系统状态进行一次计算就可以获得其一步预测结果是卡尔曼滤波算法的过程, 这与无迹卡尔曼滤波大相径庭, 无迹卡尔曼滤波需要使用一系列采样点的一步预测, 融合其信息得到非线性系统状态与其估计误差协方差矩阵的一步预测结果, 信息融合的比例基于式(2.32)得到的权重 $w^{(i)}$

$$\hat{X}(k + 1|k) = \sum_{i=0}^{2n} w^{(i)} X^{(i)}(k + 1|k) \quad (2.36)$$

$$P(k + 1|k) = \sum_{i=0}^{2n} w^{(i)} [\hat{X}(k + 1|k) - X^{(i)}(k + 1|k)][\hat{X}(k + 1|k) - X^{(i)}(k + 1|k)]^T + Q \quad (2.37)$$

(5) 使用无损变换基于一歩预测结果产生新的采样点集。

$$X^{(i)}(k + 1|k) = [\hat{X}(k + 1|k) \quad \hat{X}(k + 1|k) + \sqrt{(n + \delta)P(k + 1|k)} \quad \hat{X}(k + 1|k) - \sqrt{(n + \delta)P(k + 1|k)}] \quad (2.38)$$

(6) 计算观测值的一步预测结果, 通过代入新的采样点集到观测方程中, $i = 1, 2, \dots, 2n + 1$ 。

$$Z^{(i)}(k + 1|k) = h(X^{(i)}(k + 1|k)) \quad (2.39)$$

(7) 将观测值的一步预测结果信息融合得到无迹卡尔曼滤波本次迭代的协方差与均值

$$\bar{Z}(k + 1|k) = \sum_{i=0}^{2n} w^{(i)} Z^{(i)}(k + 1|k) \quad (2.40)$$

$$P_{Z_k Z_k} = \sum_{i=0}^{2n} w^{(i)} [Z^{(i)}(k + 1|k) - \bar{Z}(k + 1|k)][Z^{(i)}(k + 1|k) - \bar{Z}(k + 1|k)]^T + R \quad (2.41)$$

$$P_{X_k Z_k} = \sum_{i=0}^{2n} w^{(i)} [X^{(i)}(k + 1|k) - \hat{X}(k + 1|k)][Z^{(i)}(k + 1|k) - \bar{Z}(k + 1|k)]^T \quad (2.42)$$

(8) 计算卡尔曼增益矩阵

$$K(k + 1) = P_{X_k Z_k} P_{Z_k Z_k}^{-1} \quad (2.43)$$

(9) 最后, 更新该非线性系统的目标状态与协方差矩阵。

$$\hat{X}(k + 1|k + 1) = \hat{X}(k + 1|k) + K(k + 1)[Z(k + 1) - \hat{Z}(k + 1|k)] \quad (2.44)$$

$$P(k + 1|k + 1) = P(k + 1|k) - K(k + 1)P_{Z_k Z_k} K^T(k + 1) \quad (2.45)$$

根据上述的无迹卡尔曼滤波算法在时刻 k 最优估计随机变量 X 的基本步骤可以看出, 无迹卡尔曼滤波与扩展卡尔曼滤波处理同一问题时采用的方法并不相同, 无迹卡尔曼滤波不需要在滤波值处对系统方程求导进行 Taylor 级数展开, 并通过省略二阶及二阶以上的项来获得近似线性化滤波模型, 取而代之计算获得无迹卡尔曼滤波本次迭代的 Sigma 点集与协方差和均值, 该 Sigma 点集与预设的统计特性相关, 计算的方法是在滤波值附近进行无损变换, 近似的密度函数可由该 Sigma 点集非线性影射得到。密度函数近的似性不是近似解, 而是广义上的近似。

2.4 模糊神经网络

2.4.1 模糊数学介绍

模糊数学中“模糊”是指研究的主题, 而“数学”是指研究的方法, 因此模糊数学是一种调查、研究及分析事物的模糊特性的数学。

模糊数学中有两个很重要的概念是隶属函数和隶属度。其中, 隶属函数通常是三角函数、正态函数和梯形函数等, 这些函数计算隶属度时较其他函数更简便。隶属度代表元素 μ 隶属于其所在模糊子集 f 的程度, f 一般在 0 到 1 之间。 $\mu_f(u)$ 越大, 元素 u 隶属于 f 的程度越大。

2.4.2 T-S 模糊模型

T-S 模糊系统是一种会自更新、自适应模糊子集隶属函数的模糊系统, 其具有高度自适应特性。T-S 模糊系统中模糊规则 R^i 的推导一般以条件结果的形式来定义, 如下:

$$R^i: \text{If } x_1 \text{ is } A_1^i, x_2 \text{ is } A_2^i, \dots, x_k \text{ is } A_k^i \text{ then } y_i = p_0^i + p_1^i x_1 + \dots + p_k^i x_k \quad (2.46)$$

上式中, If 部分即条件部分是模糊的, 而 then 部分即结果部分是可知的, A_j^i 为模糊系统的模糊集, y_i 是输入部分 x_k 根据模糊系统参数 p_j^i 信息融合的结果, 上式 T-S 模糊系统中模糊规则 R^i 的推导可以表示为输入部分与输出部分的线性组合。

假设有输入部分 $x = [x_1 \quad \dots \quad x_k]$, 根据模糊规则可以得到各输入部分 x_j 的隶属度:

$$\mu_{A_j^i} = \exp\left(-\left(x_j - c_j^i\right)^2 / b_j^i\right) \quad j = 1, 2, \dots, k; i = 1, 2, \dots, n \quad (2.47)$$

上式中, c_j^i 是隶属函数的中心, b_j^i 是隶属函数的宽度, k 为输入部分 x_j 的个数, n 为模糊子集数。

模糊运算的算子为连乘, 将由模糊规则得到的各输入部分 x_j 的隶属度连乘进行模糊运算

$$w^i = u_{A_j^1}(x_1) * u_{A_j^2}(x_2) * \dots * u_{A_j^k}(x_k) \quad i = 1, 2, \dots, n \quad (2.48)$$

最终可以得到模糊运算的结果即 T-S 模糊模型的输出 y_i

$$y_i = \sum_{i=1}^n w^i (p_0^i + p_1^i x_1 + \dots + p_k^i x_k) / \sum_{i=1}^n w^i \quad (2.49)$$

2.4.3 T-S 模糊神经网络

T-S 模糊神经网络通常分为输入层、隶属函数层、T-范数层、输出层这四层。输入层用于输入向量 x_i 的输入，其节点数与输入向量 x_i 的输入维数相同，该层一般与输入向量直接连接。隶属函数层使用隶属函数根据模糊规则可以得到各输入部分的隶属度。T-范数层模糊运算的算子为连乘，将由模糊规则得到的各输入部分的隶属度连乘进行模糊运算。输出层用于输出 T-S 模糊神经网络的输出结果。

模糊神经网络的学习算法若采用梯度下降法如下

(1) 误差计算

$$e = \frac{1}{2} (y_d - y_c)^2 \quad (2.50)$$

上式中， y_d 是模糊网络的期望输出； y_c 是模糊网络的实际输出； e 为由期望输出和实际输出计算得到的误差。

(2) 系数修正

$$p_j^i(k) = p_j^i(k-1) - \alpha \frac{\partial e}{\partial p_j^i} \quad (2.51)$$

$$\frac{\partial e}{\partial p_j^i} = (y_d - y_c) w^i / \sum_{i=1}^m w^i \cdot x_j \quad (2.52)$$

上式中， p_j^i 为神经网络的参数， α 为预先设置的网络学习率， w^i 为由模糊规则得到的各输入部分 x_j 的隶属度连乘进行模糊运算的结果， x_j 为模糊神经网络的输入变量

(3) 参数修正

$$c_j^i(k) = c_j^i(k-1) - \beta \frac{\partial e}{\partial c_j^i} \quad (2.53)$$

$$b_j^i(k) = b_j^i(k-1) - \beta \frac{\partial e}{\partial b_j^i} \quad (2.54)$$

上式中， $c_j^i(k)$ 为隶属度函数的中心， $b_j^i(k)$ 为隶属度函数的宽度。

2.5 线性组合

线性组合是线性代数的基础知识，设 $\alpha_1, \alpha_2, \dots, \alpha_e (e \geq 1)$ 是域 P 上向量空间 V 中个数为 e 的向量。若 V 中向量 α 可以表示为：

$$\alpha = k_1 \alpha_1 + k_2 \alpha_2 + \dots + k_e \alpha_e (k_e \in P, e = 1, 2, \dots, s) \quad (2.55)$$

那么 α 可以线性表示为向量组 $\alpha_1, \alpha_2, \dots, \alpha_e$ 的一个线性组合

定义一个实数变量集 x_1, x_2, \dots, x_k ，其数量为 k 。如果变量 s 可以由实数权系数集 w_1, w_2, \dots, w_k 和实数变量集 x_1, x_2, \dots, x_k 通过加权融合得到，即 $s = w_1x_1 + w_2x_2 + \dots + w_kx_k$ ，那么将 s 定义为变量的线性组合。

如果将线性组合引申到矢量中。将实数变量集 x_i 替换为矢量集，每个矢量所含的元素数量相同，那么该矢量集的线性组合 s 也是一个矢量， s 的每个分量都可以由矢量集合中的某些矢量线性表出。

第3章 基于序列跟踪目标图像恢复的卡尔曼滤波方法

3.1 引言

在智能图像处理系统快速发展的过程中,针对目标跟踪图像的增强技术,得到人们的广泛关注。目标序列跟踪图像是传感器针对一个运动目标进行持续跟踪获得的序列图像,计算机通过分析这些图像可以获得比人类视觉观测更完善的信息。图像质量的好坏是计算机处理与决断的重要影响因素,不过图像在成像、传输等环节,极易受到有损压缩、数模转换格式等因素影响,使获得图像常常难以直接应用。因此如何通过对上述变化进行有效建模以重构出高质量的图像是智能图像处理领域面临的重要问题之一。

目前,各国学者在进行广泛深入地探索研究之后,提出了各种各样的图像增强算法,譬如卡尔曼滤波算法,均值滤波算法,小波去噪算法等都可以直接或间接地去除图像信息中噪声的部分影响,这些图像增强算法的优点是简便可行,但其不足在于对单幅受损图像进行复原所获得的效果有限,当污染图像的噪声过大或图像发生较大变形时,就难以满足任务对图像质量的需求^{[11]-[13]}。图像融合技术是取同一目标的多幅图像进行融合去噪处理,将多幅受损图像中的有用信息集中在一幅图像中,利用这些图像信息进行互补和冗余,可以获得更好的效果,但是这些图像融合技术对于图像的要求较为严苛,即受损图像集不能发生形变^{[14]-[15]}。

卡尔曼滤波算法可以去除图像信息中噪声的部分影响,但是当污染图像的噪声过大或图像发生较大变形时,该算法的效能明显不足。考虑到卡尔曼滤波框架可以融合序列图像,并且框架下的观测模型可以模拟图像的形变,因此本章提出了基于序列跟踪目标图像恢复的卡尔曼滤波方法与基于大数定律的序列图像融合方法。一方面,通过大数定律与卡尔曼滤波的原理将多幅受损图像的信息融合以重构出原始图像,解决了对单幅受损图像进行复原所获得效果有限的问题;另一方面,通过建立卡尔曼滤波框架下的系统模型和观测模型,模拟目标序列跟踪图像在持续发生形变时,基于卡尔曼滤波的图像恢复方法,可以将普通图像融合技术无法处理的受损图像集进行融合以重构出原始图像,解决了图像融合技术对于图像要求严苛的问题。

本章的主要研究思想与研究方案是:针对当污染图像的噪声过大或图像发生了形变时,由于单张受损图像的滤波无法达到任务对恢复图像质量需求的场景下,通过卡尔曼滤波器对顺序得到的多幅受损图像的信息,进行互补与冗余以解决问题,并对受损图像发生非线性变换的情况进行展望与准备。

本章安排如下,第3.2节建立目标序列跟踪图像观测系统模型,第3.3节叙述基于大数定律的序列图像融合方法,第3.4节叙述基于序列跟踪目标图像恢复的卡尔曼滤波方法,第3.5节将本章提出的方法与传统滤波算法展开全面深入地对比研究,再通

过仿真分析的方式对新算法的合理性、严谨性进行科学合理地检验^{[16]-[20]}。

3.2 目标序列跟踪图像观测系统模型

对一个慢速运动的目标，观测系统顺序获得其观测图像如下

$$Y(k) = h(X(k)) + V(k), k = 1, 2, \dots, N \quad (3.1)$$

上式中， $X(k)$ 为第 k 时刻的目标图像， $Y(k)$ 为第 k 个观测图像， $V(k)$ 指的是被污染的第 k 个观测图像相对应的观测噪声矩阵， h 指的是第 k 个观测图像相对应的观测矩阵。

- ① 当观测系统对目标同角度同距离观测时，即 $h(X(k)) = X(k)$ 。
- ② 当观测系统对目标序列跟踪图像进行线性压缩时，即 $h(X(k)) = H(k)X(k)$ 。
- ③ 当观测系统的目标序列跟踪图像进行非线性压缩时，则 $h(X(k))$ 不能分离成 $H(k)$ 与 $X(k)$ 的乘积。

3.3 常用滤波方法介绍

3.3.1 中值滤波

中值滤波是当前备受业界人士推崇与青睐的一种专业图像处理手段，尤其是在非线性系统滤波问题处理上具有无与伦比的强大优势。图 3.1 是中值滤波的示意图，通过作用机制分析发现，它是以计数排序为基础将噪声干扰降到最低的一种处理技术。客观来讲，中值滤波具有一些线性滤波方法没有的优异特性，如针对脉冲噪声具有出色的滤波效果，滤除噪声时还可以防止信号边缘被模糊，不仅如此，此算法具有适用范围广、操作简单的优势。所以，中值滤波一经提出就引发了业界人士的争相探讨与积极研究，并成为了数字信号处理领域的“宠儿”。

$$g = \text{median}[f(x-1, y-1) + f(x, y-1) + f(x+1, y-1) + f(x-1, y) + f(x, y) + f(x+1, y) + f(x-1, y+1) + f(x, y+1) + f(x+1, y+1)]$$




图 3.1 中值滤波示意图

通过实现原理分析进一步了解到，中值滤波是将数字图像或随机序列中一点的值用该点的一个邻域的中值来替代，以最大限度地缩小该点的值与附近真实值的差距，从而达到精准清除噪声点的目的。具体来讲，对 $x_j (-\infty < j < \infty)$ 进行滤波时需完成以下操作：首先要建立一个奇数长窗口。假定信号样本存在 $x(i-N), \dots, x(i), \dots, x(i+N)$ ，其中 $x(i)$ 为信号样本值，按照由大到小的顺序对所有信号样本值进行有序排列，由此

确定出序列 i 处的信号样本值，也就是中值滤波器的输出值。中值滤波在图像处理领域中的应用就是将所有像素点的灰度值替换为该点在某邻域的中值，一般以各种结构形式的二维滑动模板最为常见，比如正方形、圆形、十字形等，如同随机序列的处理方法，对模板内的所有像素进行排序，取序列中值作为中值滤波输出值 $g(x,y) = \text{med}\{f(x-k,y-i), (k,i \in W)\}$ ，其中 $g(x,y)$ 是处理后的图像， $f(x,y)$ 是原始图像， W 为二维滑动模板。

显而易见的是，中值滤波中选用的二维滑动模板越大，滤波过程中的运算量也越大。因此，如何探索出精准且高效的中值滤波快速算法就成为了学术界争相探讨与积极研究的焦点课题，在学术界人士的不懈努力下提出了很多引以为傲的研究成果，但备受人们推崇与青睐的快速算法主要有三种，一是网络选择法，二是逻辑判断法，三是直方图数据修正法。值得一提的是，根序列的描述和统计特性分析也是不容忽视的一项重要研究内容，只要数字信号序列经中值滤波器数次处理后，它就会成为一个相对固定的序列，业界人士习惯将这种序列定义为根序列。根序列是中值滤波特性分析的核心依据，通过根序列结构分析可精准确定各自成分的效用，进而也就能协助人们做出去留选择。因此，对根序列结构展开全面且深入地探讨与研究有利于人们确定出相适应的窗口长度。

中值滤波在工程中的主要实现方法是通过从数字图像中的某个用于采样的二维滑动窗口提取奇数个样本数据，再根据样本数据的大小对其进行排序，最后将需要处理的数据替换为经过排序后的样本数据中值即可。倘若中值滤波器芯片能基于超大规模集成电路实现，也就意味着能支持实时处理。

由于中值滤波方法在清除椒盐噪声、相位分析处理等方面具有无与伦比的强大优势，所以该算法在图像领域的信号模糊处理上备受推崇与青睐，进而成为学术界声望最高且最容易实现的一种经典降噪方法。

3.3.2 均值滤波

均值滤波是当前使用频率最高的一种经典算法。就实现机理上来看，它是将受损图像中的所有像素值替换成为该像素在滤波模板中的各像素平均值。简单来讲，就是先为待处理的像素点 (x,y) 匹配相适应的二维滤波模板，再将 (x,y) 的像素值全部更换为模板中的各像素平均值，由此生成该点的灰度值 $g(x,y)$ ，即 $g(x,y) = \sum f(x,y)/m$ ，其中， m 指的是二维滤波模板中的像素总量。目前，这种算法主要基于邻域平均法来实现，也就是将目标像素作为中心，与邻近的 8 个像素打造成为 3×3 的正方形滤波模板，再将像素值替换成为平均值，图 3.2 是均值滤波的示意图。




图 3.2 均值滤波示意图

均值滤波具有其自身的缺陷,即待处理数字图像的图像细节无法得到适当的保护,孤立的噪声点难以被良好地去除。

3.3.3 指数滤波

指数平滑法是一种经典且成熟的预测策略,现已受到业内人士的高度推崇和积极应用,很多学者在对经济发展情况进行估测分析时采用此方法。对时间数列的所有历史数据完全以同等权重使用的方法被业内人士称作为全期平均法;在忽略远期从前信息的基础上,在进行处理分析的过程中,将较高的权重科学合理地分配至最新数据上,此方法即为当前应用相对比较广泛的称移动平均法;上述方法各有千秋,均有其自身优势和不足,而指数平滑法则灵活合理地汲取了它们的优势,此方法的特点是随着时间的推进,远期的先前信息所产生的影响慢慢地减弱。

指数滤波从本质上来讲属于指数平滑法范畴,不过其表现形式较为特殊,概括来讲,它主要具有如下特性:第一,重视并强化对近期观测值的获取,同时深入细致地分析其对预测值所产生的重要影响,对各时间节点对应的观察值分配合适的权重,它们通常是根据等比级数的方式进行递减,其首项为平滑常数 a ,公比为 $(1 - a)$,能够在一定程度上提高近期观测值对预测值的加权重,使得如此加权得到的预测值可以快速反映市场的实际变化。第二,指数平滑法对于不同时刻观测值所分配的加权重是灵活的,加权重数的变化率可以由 a 的各种取值策略更改,趋势变化的平稳度即时间序列观测值的均匀性可以通过选取不同 a 值来调整,例如 a 是一个较小的值,则观测期内近期观测值的最新趋势会迅速反映于预测值中,加权重数的变化率更大。

简而言之,指数平滑法融合了传统方法的精髓与优势,利用完善严谨、科学合理的时间序列预测模型科学高效地推导出指数平滑值,同时对整个时间序列展开深入全面地研究,并进行科学合理地估测。

指数平滑法可以根据平滑次数的差异分为不同种类:一是一次指数平滑法,该方法主要适用于时间序列比较稳定且不会出现较大波动的情况;二是二次指数平滑法,若时间序列持续出现了线性变化的迹象,那么可对基于一次平滑法得出的推测值继续平滑;三是三次指数平滑方法,即指的是在时间序列持续出现了线性变化的迹象时,那么可对基于二次平滑法得出的推测值继续平滑处理。不管是哪一种方法,其作用机

制均是预测结果乃历史观测结果加权总和，其权重值的高低会因数据所处时期的不同而呈现出较大差别，一般来讲，历史数据被赋予的权重比较小，而当前获取的新数据则往往被赋予较大的权重。

若某时期内采集到数据有所升高或者有所变小，即意味着指数预测结果和实际结果之间存在一定偏差，前者相对较为滞后。引入趋势校正值等方法能够减少偏差，主要包含指数平滑预测计算、趋势计算与趋势调整后的指数平滑预测值计算这三个步骤。

3.3.4 窗口滤波

窗口滤波是以滑动窗口协议为基础的一种滤波方法，滑动窗口协议是流量传输协议中的一种用于控制流量的协议，即流量传输协议的三次握手中，每次只发两个数据包，在网络阻塞的时候，数据发送方根据数据接收方反馈的大小，来调整接下来发送数据包的大小。于是，学者们根据这个思想提出了递推平均算法，即先建立一个定长队列，每次队尾添加一个新数据时，就从队首删除一个数据，求取这个新增数据与删除数据的均值。

例如对一组数据使用窗口滤波时，需要先去除数据中不符合规格与明显无效的数据，再对其进行排序，根据要处理的问题预设一个阈值，建立一个长度为 4 的滑动窗口，从数据序列头部向尾部滑动，每滑动一次就计算滑动窗口头部与尾部的差值，如果差值小于阈值则保留，否则丢弃，最后选取保留的差值中最小的 4 项，这 4 项的平均值即窗口滤波的输出结果。

窗口滤波的窗口大小与预设的阈值大小是影响其效能的关键。如果窗口过大，则对原始数据的要求将会变高，特别是在测量环境不佳的情况下，窗口过大会导致滤波的适应性变差；如果窗口过小，则提取的数据并不能保证全部分布在有效范围内。预设的阈值过大可能会导致结果出错，过小则会大幅压缩测量的量程。人们往往会在考虑实际情况的基础上，基于个人掌握的经验与知识科学合理地设定窗口大小以及预设的阈值大小，这样才能够获得更好的滤波效果。

3.3.5 维纳滤波

维纳滤波器的主要作用是尽可能地降低预测误差均方值。维纳在连续时间信号的线性最优滤波器的开拓性工作中发展得到离散时间维纳滤波理论。为广义平稳随机信号的线性滤波提供了合理架构，使得维纳滤波器成为里程碑^[21]。

维纳滤波是一种可以去除时序信号噪声的滤波方法，其基本框图如下




图 3.3 维纳滤波基本框图

维纳滤波本质上是一个通过 FIR 滤波器滤除噪声的手段。上图中， h 是对系统信号与噪声的建模，通过先前时刻的信息预测噪声与信号的比例，系统可以根据该比例去除噪声，这样即达成了滤波效果。

维纳滤波器是一种使用灵活，应用广泛的滤波器，其有很多种变化形式，比如其可以使单输入单输出，也可以是多输入多输出。对系统信号与噪声的建模可以是线性的，亦可以使非线性的。底层可以使用 FIR 滤波器，也可以使用 IIR 滤波器。使用者可以根据要解决的问题灵活的选择维纳滤波器的架构。但是无论使用哪种架构，维纳滤波的基本思想通过滤波从信号与噪声的混合中提取出信号，其核心在于计算维纳滤波器的参数，即求解 Wiener-Hop 方程。

维纳滤波器也有其自身的限制，即其要求输入的信号是广义上平滑的。维纳滤波器也具有两个比较突出的特征：一是正交性原理，即维纳滤波处理数据过程中的误差信号与输入信号常保持着正交关系。二是误差信号的分布多以高斯白噪声为主。

3.4 基于大数定律的序列图像融合方法

观测系统在满足第 2 节条件①的情况下，模型(1)被建模为

$$Y(k) = X + V(k), k = 1, 2, \dots, N \quad (3.2)$$

$Y(k)$ 是带有独立同分布随机变量矩阵 $V(k)$ 的图像序列，基于大数定律可得图像 X 的估计值

$$\hat{X}(n) = \frac{1}{n} \sum_{k=1}^n Y(k) = \frac{1}{n} \sum_{k=1}^n [X + V(k)] = X + \frac{1}{n} \sum_{k=1}^n V(k) \quad (3.3)$$

上式中， $\hat{X}(n)$ 为前 n 个序列观测图像共同获得的图像 X 的估计值。

目标图像估计值与原图的差异可表示为

$$\tilde{X}(n) = \hat{X}(n) - X = \frac{1}{n} \sum_{k=1}^n Y(k) - X = \left(X + \frac{1}{n} \sum_{k=1}^n V(k) \right) - X = \frac{1}{n} \sum_{k=1}^n V(k) \quad (3.4)$$

假设观测图像中加入的观测噪声矩阵 $V(k)$ 服从方差相同、数学期望为 0 的高斯白噪声统计分布，根据辛钦大数定律，随着序列观测图像累加数量的增加，目标图像估计值与原图的差异将不断减小，最终能够得到序列观测图像的融合去噪结果。

3.5 基于卡尔曼滤波的图像恢复方法

3.5.1 卡尔曼方程组的矩阵形式描述

观测系统在满足第 2 节条件②的情况下，模型(1)被建模为

$$Y(k) = H(k)X(k) + V(k), k = 1, 2, \dots, N \quad (3.5)$$

为了将其改写成基于序列融合的卡尔曼滤波方程组形式，将其动态特性建模为随时间 k 缓变的序列图像，模型如下

$$X(k+1) = A(k)X(k) + W(k), k = 0, 1, 2, \dots, N \quad (3.6)$$

上式中, $X(k)$ 为第 k 时刻观测图像对应的目标状态, 假设 $X(0)$ 为目标初始状态的矩阵, $A(k)$ 为其对应状态转移矩阵, $W(k)$ 为零均值的高斯白噪声。

为此, 测量方程改写为

$$Y(k+1) = H(k+1)X + V(k+1), k = 0, 1, 2, \dots, N \quad (3.7)$$

上式中, $Y(k+1)$ 为第 $k+1$ 时刻的观测图像, $H(k+1)$ 为其对应的观测矩阵, $V(k+1)$ 为零均值的高斯白噪声

3.5.2 卡尔曼方程组的列向量形式描述

考虑到目前没有主要是基于图像形式的卡尔曼滤波器, 为此将上式中(3.6)、(3.7)下系统方程改写以列向量为基本单位的形式, 即

$$X(k) : [x_1(k) \ x_2(k) \ \dots \ x_j(k) \ \dots \ x_n(k)] \quad (3.8)$$

$$W(k) : [w_1(k) \ w_2(k) \ \dots \ w_j(k) \ \dots \ w_n(k)] \quad (3.9)$$

$$Y(k) : [y_1(k) \ y_2(k) \ \dots \ y_j(k) \ \dots \ y_n(k)] \quad (3.10)$$

$$V(k) : [v_1(k) \ v_2(k) \ \dots \ v_j(k) \ \dots \ v_n(k)] \quad (3.11)$$

上式中, $x_j(k)$ 为第 k 时刻的目标图像 $X(k)$ 第 j 列的像素灰度值, 其余类同。

基于(3.8)~(3.11)将状态方程、观测方程科学合理地构建为一个规范标准的方程组:

$$x_j(k+1) = A(k)x_j(k) + w_j(k), k = 0, 1, 2, \dots, N; j = 1, 2, \dots, n \quad (3.12)$$

$$y_j(k) = H(k)x_j(k) + v_j(k), k = 0, 1, 2, \dots, N; j = 1, 2, \dots, n \quad (3.13)$$

$$w_j(k) \sim N[0, Q(k)], k = 0, 1, 2, \dots, N; j = 1, 2, \dots, n \quad (3.14)$$

$$v_j(k) \sim N[0, R(k)], k = 0, 1, 2, \dots, N; j = 1, 2, \dots, n \quad (3.15)$$

3.5.3 目标序列观测图像融合的卡尔曼滤波方法

假设给定状态初始估计值 $\hat{x}_j(0)$ 和状态初始估计协方差矩阵 $P_j(0)$, 基于前 k 个观测值可得目标图像第 j 列的估计值

$$\hat{x}_j(k|k) = E\{x_j(k) | \hat{x}_j(0), y_j(2), \dots, y_j(k)\} \quad (3.16)$$

与第 k 时刻状态估计协方差矩阵

$$P_j(k|k) = E\{[x_j(k) - \hat{x}_j(k|k)][x_j(k) - \hat{x}_j(k|k)]^T\} \quad (3.17)$$

1) 卡尔曼滤波器一步预测方程

(1) 状态估计值一步预测方程

$$\hat{x}_j(k+1|k) = E\{x_j(k+1) | \hat{x}_j(0), y_j(2), \dots, y_j(k)\} = A(k)\hat{x}_j(k|k) \quad (3.18)$$

(2) 状态估计值误差协方差矩阵一步预测方程

$$P_j(k+1|k) = E\{[x_j(k+1) - \hat{x}_j(k+1|k)][x_j(k+1) - \hat{x}_j(k+1|k)]^T\} = A(k)P_j(k|k)A(k)^T + Q \quad (3.19)$$

(3) 测量值一步预测方程

$$\hat{y}_j(k+1|k) = H(k+1)\hat{x}_j(k+1|k) \quad (3.20)$$

2) 最优增益阵 $U_j(k+1)$ 计算

$$U_j(k+1) = P_j(k+1|k)H(k+1)^T[H(k+1)P_j(k+1|k)H(k+1)^T + R]^{-1} \quad (3.21)$$

3) 状态估计值和估计误差得到实时更新方程

$$\hat{x}_j(k+1|k+1) = \hat{x}_j(k+1|k) + U_j(k+1)[y_j(k+1) - \hat{y}_j(k+1|k)] \quad (3.22)$$

$$P_j(k+1|k+1) = [I - U_j(k+1)H(k+1)]P_j(k+1|k) \quad (3.23)$$

上式中, $I = \begin{bmatrix} 1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 1 \end{bmatrix}$ 。

4) 基于序列观测图像 $Y(1)$ 、 $Y(2)$, ..., $Y(N)$ 的卡尔曼滤波融合结果即目标图像 X 的估计值为

$$\hat{X}(N|N) = E\{X|Y(1), \dots, Y(j), \dots, Y(N)\} = [\hat{x}_1(N|N), \dots, \hat{x}_j(N|N), \dots, \hat{x}_n(N|N)] \quad (3.24)$$

其中

$$\hat{x}_j(N|N) = E\{x_j|\hat{x}_j(0), y_j(2), \dots, y_j(N)\} \quad (3.25)$$

上述过程中, $j = 1, 2, \dots, n$ 。

5) 算法流程描述

基于卡尔曼滤波的图像恢复方法流程如下:

步骤 1: 流程初始化

(1) 给定状态估计值初始化 $\hat{x}_j(0)$ 与状态估计协方差初始化 $P_j(0)$ 。

(2) 基于(3.16)和(3.17)的 k 时间节点下所对应的最佳预测值 $\hat{x}_j(k|k)$ 及其预测误差协方差矩阵 $P_j(k|k)$ 。

步骤 2: 根据步骤 1 得到一步预测结果

(1) 基于(3.18)的状态估计值一步预测 $\hat{x}_j(k+1|k)$ 。

(2) 基于(3.19)的状态预测值误差协方差矩阵一步预测 $P_j(k+1|k)$ 。

(3) 基于(3.20)测量值一步预测 $\hat{y}_j(k+1|k)$ 。

步骤 3: 根据(3.21)计算最优增益阵 $U_j(k+1)$ 。

步骤 4: 状态估计实时更新: 根据(3.22)的状态估计值更新 $\hat{x}_j(k+1|k+1)$ 和根据(3.23)的状态估计值误差协方差矩阵更新 $P_j(k+1|k+1)$ 。

步骤 5: 返回步骤 2, 重复步骤 2-4 直到滤波结束, 即 $j = 1, 2, \dots, n; k = 1, 2, \dots, N$ 。

步骤 6: 得到基于卡尔曼滤波的图像恢复方法结果即(3.24)中 $\hat{X}(N|N)$ 。

3.6 仿真实验

3.6.1 数据来源及评价方法

本章选取经典的 Lena 图像进行灰度转换作为原图即目标图像。

对于去噪处理后的图像,人们倾向于通过两个指标对其质量进行客观全面地评估:一是标准均方差 MSE,二是峰值信噪比 PSNR

$$MSE = \frac{1}{ij} \sum_{i=1}^m \sum_{j=1}^n [\hat{x}_{ij}(N|N) - x_{ij}]^2 \quad (3.26)$$

$$PSNR = 20 * \log_{10} \left(\frac{MAX_K}{\sqrt{MSE}} \right) \quad (3.27)$$

上式中, $\hat{x}_{ij}(N|N)$ 为去噪后图像的像素灰度值, x_{ij} 为原图图像的像素灰度值。 MAX_K 是表示图像点颜色的最大数值,若所有采样点均通过 8 位的形式进行存在和展示,即为 255。

标准均方差 MSE 能够比较准确客观地体现滤波处理后的图像与原图的近似度,一般来讲,其值愈小,近似度愈高。关于峰值信噪比 PSNR,一般来讲,其值愈大,滤波效果愈理想。

3.6.2 基于大数定律的序列图像融合方法仿真

当观测系统针对原图获得被高斯白噪声污染的序列观测图像即

$$Y(k) = H(k)X + V(k), k = 1, 2, \dots, 20 \quad (3.28)$$

上式中 $H(k)$ 都为单位矩阵, X 为原图, $V(k) = [v_{ij}]$, $v_{ij} \sim N(0, 0.04)$ 为附加在每个像素点上的高斯白噪声。



图 3.4 基于大数定律的序列图像融合方法效果图



图 3.5 六种滤波方法的效果对比图




图 3.6 基于大数定律的序列图像融合方法 PSNR 曲线图

表 3.1 六种滤波方法的 PSNR 与 MSE

滤波方法	PSNR	MSE
大数定律	62.74	0.0019
窗口滤波	47.08	0.0090
指数滤波	44.24	0.0120
均值滤波	53.45	0.0048
中值滤波	49.22	0.0048
维纳滤波	56.41	0.0035

表 3.2 基于大数定律的序列图像融合方法的 PSNR 与 MSE

图像融合数量	PSNR	MSE
5	45.26	0.0073
10	56.09	0.0037
15	60.02	0.0025
20	62.74	0.0019

通过表 3.1 可以看出，基于大数定律的序列图像融合方法相比其他滤波方法有更好的定量评价指标。在图 3.6 中随着序列图像融合数量的增加，基于大数定律的序列图像融合方法的 PSNR 值呈上升趋势，说明该方法能够通过融合序列观测图像估计原始图像。

3.6.3 基于卡尔曼滤波的图像恢复方法仿真一

当观测系统针对原图获得被高斯白噪声污染的序列观测图像即

$$Y(k) = H(k)X + V(k), k = 1, 2, \dots, 20 \quad (3.29)$$

上式中 $H(k)$ 都为单位矩阵， X 为原图， $V(k) = [v_{ij}]$, $v_{ij} \sim N(0, 0.04 \pm \frac{(0,1)}{10})$ 为附加在每个像素点上的高斯白噪声。拟采用基于卡尔曼滤波的图像恢复方法融合这些序列观测图像达成去噪效果以估计原图，给定卡尔曼滤波器的初始条件 $Q = 0$ ， A 、 H 、 R 、 $P_j(0)$ 为 512×512 的单位阵， $\hat{x}_j(0)$ 为序列观测图像中第一幅图像卡尔曼滤波去噪的结果。



图 3.7 基于卡尔曼滤波的图像恢复方法效果图



图 3.8 基于大数定律的序列图像融合方法效果图




图 3.9 两种方法的 PSNR 曲线图

表 3.3 两种方法的 PSNR

图像融合数量	大数定律	卡尔曼滤波
5	42.64	43.94
10	49.74	50.36
15	53.70	54.09
20	55.49	55.75

通过表 3.3 可以看出，随着目标的缓慢远离，目标图像所含的噪声逐渐变大，即

当每张观测图像所含高斯白噪声的方差各不相同，基于卡尔曼滤波的图像恢复方法相比基于大数定律的序列图像融合方法有更好的定量评价指标。在图 3.9 中，卡尔曼滤波方法的 PSNR 曲线一直在大数定律方法的 PSNR 曲线之上，说明高斯白噪声方差变化条件下基于卡尔曼滤波的图像恢复方法比基于大数定律的序列图像融合方法有更好的去噪效果。

3.6.4 基于卡尔曼滤波的图像恢复方法仿真二

当观测系统的观测矩阵持续变化时，传感器获得被高斯白噪声污染且持续形变的序列观测图像为

$$Y(k) = H(k)X + V(k), k = 1, 2, \dots, 20 \quad (3.30)$$

上式中 $H(k)$ 为由 matlab 产生的随机非奇异正交矩阵， X 为原图， $V(k) = [v_{ij}]$, $v_{ij} \sim N(0, 0.04 \pm \frac{(0,1)}{10})$ 为附加在每个像素点上的高斯白噪声，拟采用基于大数定律的序列图像融合方法与基于卡尔曼滤波的图像恢复方法融合序列观测图像以重构估计原图，初始条件如 3.5.3。

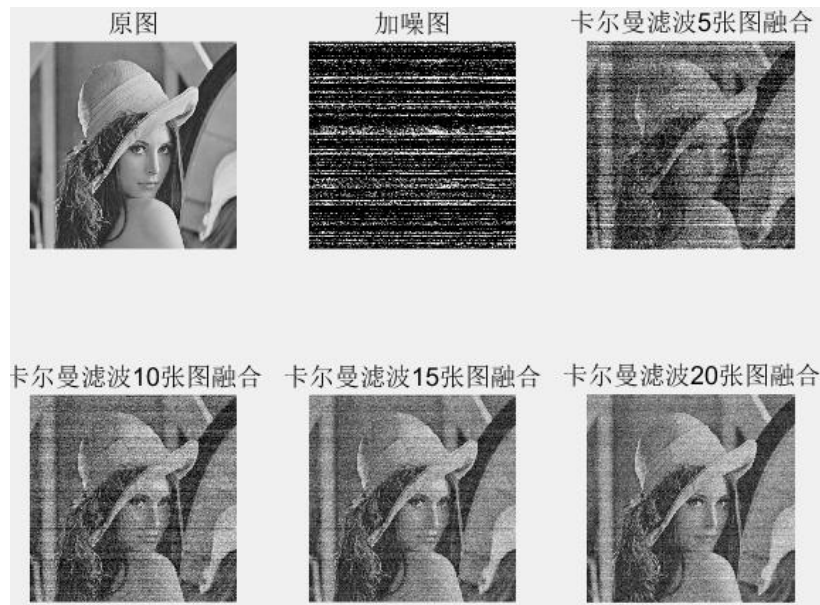


图 3.10 基于卡尔曼滤波的图像恢复方法效果图




图 3.11 两种方法的 PSNR 曲线图

表 3.4 两种方法的 PSNR

图像融合数量	大数定律	卡尔曼滤波
5	/	33.13
10	/	43.93
15	/	48.91
20	/	51.98

通过图 3.10、图 3.11 可以看出，当观测系统的观测矩阵持续变化时，基于大数定律的序列图像融合方法已然失效，而基于卡尔曼滤波的图像恢复方法仍然能够通过融合序列观测图像完成估计目标图像的任务。

3.7 总结分析

针对一个运动目标，传感器持续跟踪获得其受噪声干扰、形变影响的序列观测图像，由此本章提出了基于大数定律的序列图像融合方法与基于卡尔曼滤波的图像恢复方法，进而将方法应用于处理不同场景下的序列观测图像。实验结果表明：在序列观测图像中每幅图像所含高斯白噪声方差相同的场景下，基于大数定律序列图像融合方法能够通过融合序列观测图像得到比其他滤波方法更好的去噪效果以估计原始图像。在序列观测图像中每幅图像所含高斯白噪声方差各不相同的场景下，基于卡尔曼滤波的图像恢复方法相比其他方法有更好的定量评价指标。在序列观测图像中每幅图像持续形变且所含高斯白噪声方差各不相同的场景下，基于大数定律序列图像融合方法失

效，而基于卡尔曼滤波的图像恢复方法仍然可以通过融合序列图像以重构原始图像。

本章也存在不足，即提出的基于卡尔曼滤波的图像恢复方法只能对发生线性变换的受损图像进行融合恢复，对于发生非线性变换的受损图像并不适用，需要非线性滤波器与图像拓扑变换的引入才可以解决问题，因此本章为下面的工作做准备。

第 4 章 基于神经网络水样图像水质评价的卡尔曼滤波方法

4.1 引言

水质评价是指在特定时间特定采样水口提取水样，并通过数据模型根据水样的某些成分计算出水样的样本值，最终与环境组织预设的成分指标进行对比，得到该采样水口在采样时间的水质评价的过程。水质评价可以确定该采样水口在采样时间的水质情况，从而为防治污染和保护水源提供重要数据依据^[22]。水质评价的预设指标值主要包括 TP、TN、NH₃、DO、COD 和 KMnO₄。其中，TP 是水域中磷的浓度，是衡量水域富集的指标。TN 是水域的氮含量，也是测量水域富集的指标。NH₃ 是有机物需氧分解的产物，会导致水域富集，是衡量水域富集的标准。DO 是水中氧气的含量，众所周知水中的氧气可以促进水体的自净。COD 是指 K₂CrO₄ 与水样发生化学反应后，K₂CrO₄ 的消耗量即水样还原性物质含量。KMnO₄ 是高锰酸钾，也是一种强氧化剂，溶于水后产生大量氧气，反映了水样有机污染的程度^[23]。

本章构建的分布式神经网络结构由前置的卷积神经网络与后置的模糊神经网络构建而成，前置的卷积神经网络通过输入采样水的数字图像，输出采样水的各项水体水质的分析指标；后置的模糊神经网络通过输入采样水的各项水体水质的分析指标，输出采样水样本的水质等级。

模糊神经网络由模糊系统和神经网络构成，模糊系统的模糊规则数量通常决定着模糊神经网络的结构大小，而神经网络一般用于学习、优化、自适应调整模糊系统的变量与参数^[24]。所以一般先通过划分输入空间以确定模糊系统的模糊规则数量，然后使用神经网络学习、优化、自适应调整模糊系统的变量与参数，但是通过划分输入空间并不能有效地识别模糊规则数。网络的泛化能力是评估神经网络优点和缺点的关键，取决于网络能否成功优化调整模糊系统的参数，能否对输入空间进行合理的划分，过多的节点将导致过度拟合，而过少的节点将导致过度训练，两者都是这个模糊神经网络结构上的弊端^[25]。模糊神经网络如果采用只适应一阶模型的误差反向传播法，则调整的速度较慢，而且结果容易陷入局部最小值，所以有必要找到一个更快速的神经网络学习算法。

因此本章提出了一种基于模糊神经网络的卡尔曼滤波方法，通过扩展卡尔曼滤波科学合理地设置网络非线性参数值，同时，借助卡尔曼滤波灵活合理地修正网络线性参数。此算法明显有别于传统方法，其特殊之处主要表现为，模糊神经网络的结构不会提前设定，在开始学习之前，未设置模糊规则，一般是在学习环节，根据实际情况的演变科学合理地增加规则。基于此算法获得的模型中模糊规则数量不会随着输入变量的增加而呈指数增长。通过该算法获得的模糊神经网络结构小，可以避免过度拟合的现象，给用户带来极大的方便。该算法生成的模糊神经网络即使在不利条件下也可

以处理非线性时变系统。

本章的主要研究思想与研究方案是：提出基于神经网络水样图像水质评价的卡尔曼滤波方法，在水质监测的应用工程领域，由卷积神经网络与模糊神经网络构建分布式神经网络，输入采样水的数字图像得到其各项指标，再使用模糊神经网络分析指标进行水质监测评分，通过卡尔曼滤波器对该模糊神经网络的分布式参数优化，可获得更优的模式识别准确率。

本章安排如下，第 4.2 节主要对模糊神经网络的结构体系进行了清晰简明地论述，第 4.3 节全面细致地描述了以模糊神经网络为基础的卡尔曼滤波方法，依次从模糊规则的产生规则、模糊神经网络的参数调整、模糊神经网络的分布式参数调整与模糊规则的新增加策略分析，第 4.4 节通过构建的训练样本进行数据仿真实验，将卡尔曼滤波优化前后的模糊神经网络进行定性与定量的分析对比，以此验证滤波优化的有效性。

4.2 模糊神经网络结构

模糊神经网络中模糊规则的推导一般采用条件-结果的形式，常表现为如果 IF 输入向量满足了条件，那么 THEN 输出结果可以被分类

$$R_j: IF x_1 \text{ is } F_{1j} \text{ and ...and } x_r \text{ is } F_{rj}, THEN y_j \text{ is } b_j \quad (4.1)$$

上式中， x_i 是当前输入向量的第 i 维， F_{ij} 是其可能满足的条件，在模糊神经网络中以隶属函数的形式进行计算， y_j 是该神经网络输出向量的第 j 维， b_j 是这个输出结果可能被分到的类。上式中可以看出，如果输入向量的 x_i 分别满足了 F_{ij} 的条件，那么神经网络的输出结果 y_j 可以被分到 b_j 这个类。

基于模糊规则的这个形式，本章设计的模糊神经网络结构可以分为输入层、模糊化层、模糊规则层与输出层这四层。其中输入层用于模糊神经网络中输入向量的输入，输入层的节点数与输入向量的维数相同，输入向量一般为数据样本的归一化，归一化结果与输入层节点直接相连。模糊化层用于对输入向量进行模糊初始化，其节点数设置在实验中具体说明，模糊化层中的每个节点都是一个模糊化函数，模糊化函数一般选用高斯函数，该模糊神经网络使用的高斯函数如下

$$\mu_{ij} = \exp\left(-\frac{(x_i - c_{ij})^2}{\sigma_{ij}^2}\right), i = 1, 2, \dots, r; j = 1, 2, \dots, u \quad (4.2)$$

上式中， μ_{ij} 是 x_i 的第 j 个模糊化函数， c_{ij} 是该函数的中心， σ_{ij} 是该函数的宽度，输入向量的维数为 r ，对应模糊化函数的个数为 u 。

模糊规则层是条件-结果形式的体现，模糊系统有多少个模糊规则，该层则有多少

个节点，其中每个节点代表一条输入向量经模糊化后可能满足的条件部分。模糊规则层的输出为

$$\varphi_j = \exp\left(-\sum_{i=1}^r \frac{(x_i - c_{ij})^2}{\sigma_{ij}^2}\right) \quad (4.3)$$

输出层用于模糊神经网络的输出，是输入向量经过隐含层的模糊化与分类后得到的结果，其节点数与模糊神经网络需要解决的问题有关，每个节点代表输出向量其中的一个维度

$$y(x) = \sum_{j=1}^u b_j \varphi_j \quad (4.4)$$

上式中， $y(x)$ 是模糊神经网络输出层的输出， b_j 是模糊规则中的分类结果部分

这是一个 T-S 模型的模糊神经网络，网络的输出层的最终输出为

$$y(x) = \sum_{j=1}^u b_j \exp\left(-\left(\frac{(x - c_j)^2}{\sigma_j^2}\right)\right) \quad (4.5)$$

可以将 n 个输入向量产生的 u 个模糊规则表示为矩阵的形式

$$\varphi = \begin{bmatrix} \varphi_{11} & \cdots & \varphi_{1n} \\ \vdots & \ddots & \vdots \\ \varphi_{u1} & \cdots & \varphi_{un} \end{bmatrix} \quad (4.6)$$

上式中， φ_{ij} 是第 j 个输入向量通过隐含层模糊化与分类后得到的计算结果，因为模糊规则层输出转变为矩阵形式，则有模糊神经网络输出层的最终输出

$$Y = B\varphi \quad (4.7)$$

其中，

$$B = [b_1 \quad \cdots \quad b_u] \quad (4.8)$$

$$Y = [y_1 \quad \cdots \quad y_n] \quad (4.9)$$

4.3 基于模糊神经网络的卡尔曼滤波方法

4.3.1 模糊规则的产生规则

模糊神经网络中模糊规则层的模糊规则数量是决定网络效能的重要因素，如果模糊规则数量过多，那么网络的计算量与复杂度将会大幅度上升，如果过少，则网络的效能不能得到良好的保障。经过模糊神经网络学者的分析，一般可以通过隶属函数覆盖范围、预设误差值与误差下降速度三个层面来决定网络模糊规则的数量

1) 模糊化函数覆盖范围：模糊神经网络由模糊系统和神经网络组成，神经网络一般用于调整与优化模糊系统的参数变量，并对输入空间进行有效合理的划分，网络所用的模糊化函数也会影响网络的效能。如果网络输入层的所有输入变量被该网络的模糊化函数所覆盖，也就是说所有的输入变量都可以由该网络的模糊化函数线性表出，

那么该网络就符合模糊化函数覆盖范围这个条件，无需增加新的模糊化函数。

2) 预设误差值：预设误差值是分析估计中常用的阈值预警手段，假设有输入样本 (X_i, t_i) ， X_i 是模糊神经网络的输入， t_i 是期望的输出，通过模糊神经网络可以计算出输入样本的实际输出，如果实际输出与期望输出的差值大于预设的阈值，那么就会进行警告，表示神经网络的效能出现问题，需要增加新的模糊化函数。

3) 误差下降速度：梯度下降法是模糊神经网络中常用的一种参数更新方法，是一种一阶线性逼近方法，并不完全适用于非线性的神经网络，随着网络学习与调整迭代次数的增加，计算速度将会大幅度减慢，而且极易陷入局部最小值，于是本章尝试使用可以处理非线性滤波问题的扩展卡尔曼滤波来解决这个问题，把网络学习中的误差下降速度视作增加新的模糊化函数的信号，而不是去优化调整已存在的网络结构与参数，拟解决梯度下降法随着迭代次数增加导致的计算速度变慢及容易陷入局部最小值的问题

假设有输入输出样本 (X_i, t_i) ，可以对输入输出样本基于线性回归理论进行建模，

$$t(i) = \sum_{j=1}^u h_j(i) \theta_j + \varepsilon(i) \quad (4.10)$$

上式中， $h_j(i)$ 是回归向量， θ_j 是重构期望输出的权值向量， $\varepsilon(i)$ 是预设的误差向量，其与回归向量无关。把式(4.10)转变为矩阵的形式

$$D = H\theta + E \quad (4.11)$$

如果回归向量矩阵 H 的列数小于其行数，那么可以对其进行正交三角分解

$$H = PQ \quad (4.12)$$

回归向量矩阵 H 经过正交三角分解后可以得到正交基向量集 $P = [p_1 \ \dots \ p_u]$ 与一个上三角矩阵 Q ，这个正基向量集 P 是解决问题的关键，因为其中的每个正交基向量都可以推算出输入向量元素重构期望输出的权重，把式(4.12)代入式(4.11)，有

$$D = PQ\theta + E = PG + E \quad (4.13)$$

上式中， G 的最小二乘解可以表示为

$$g_k = \frac{p_k^T D}{p_k^T p_k}, k = 1, 2, \dots, u \quad (4.14)$$

当 $k \neq l$ 时， p_k 和 p_l 正交，有 D 的平方和

$$D^T D = \sum_{k=1}^u g_k^2 p_k^T p_k + n^{-1} E^T E \quad (4.15)$$

舍弃其均值后，有 D 的方差

$$n^{-1} D^T D = n^{-1} \sum_{k=1}^u g_k^2 p_k^T p_k + n^{-1} E^T E \quad (4.16)$$

上式中， $n^{-1} \sum_{k=1}^u g_k^2 p_k^T p_k$ 是期望输出的方差，其中 p_k 的误差下降率为

$$err_k = \frac{g_k^2 p_k^T p_k}{D^T D} \quad (4.17)$$

把式(4.14)代入式(4.17)有

$$err_k = \frac{(p_k^T D)^2}{p_k^T p_k D^T D} \quad (4.18)$$

上式中, err_k 代表 D 与 p_k 的相似度, err_k 越大, D 与 p_k 就越相似, p_k 对期望输出的贡献就越大, 因此上式是寻找最大贡献的回归向量的重要方法

定义泛化因子 GF

$$GF = \sum_{k=1}^u err_k \quad (4.19)$$

泛化因子 GF 表示该模糊神经网络的泛化能力, 可以根据泛化因子 GF 来决定是否需要加入新的模糊化函数, 但是需要人为预设一个阈值 K_{GF} , 如果泛化因子 GF 不满足阈值 K_{GF} , 那么需要往网络中添加新的模糊化函数。

4.3.2 模糊神经网络的参数调整

模糊神经网络参数的调整方法一般有最小二乘法与梯度下降法两种。最小二乘法的优势在于其运算量不大而且运算速度较快, 但是其也存在自身的固有缺陷, 即其运算速度深受噪声的影响。梯度下降法是适用于一阶模型的调整方法, 并不适用于非线性性的神经网络, 当网络学习与调整的迭代次数增加时, 梯度下降法的速度会明显减慢, 且容易陷入局部最小值。

扩展卡尔曼滤波是一种可以解决非线性问题的常用算法, 其被用于模糊神经网络的学习时的表现良好, 与最小二乘法与梯度下降法不同的是扩展卡尔曼滤波不是用于自适应调整优化模糊神经网络的现有结构与参数, 而是在网络的训练过程中, 根据定义的泛化因子 GF 逐渐加入新的模糊化函数, 将扩展卡尔曼滤波与模糊神经网络结合可以得到合理的网络结构与优秀的分类结果

现对一个非线性系统进行建模, 得到方程组

$$X(k+1) = f(X(k)) + W(k) \quad (4.20)$$

$$Y(k) = h(X(k)) + V(k) \quad (4.21)$$

上式中, $X(k)$ 是该非线性系统在时刻 k 的状态, $f(\cdot)$ 是该系统的状态转移矩阵, 是一个非线性函数, $W(k)$ 是预设的系统噪声, 其为高斯白噪声, $Y(k)$ 是时刻 k 对应的观测值, $h(\cdot)$ 是该系统的观测矩阵, 也是一个非线性函数, $V(k)$ 是观测噪声, 也是一个高斯白噪声, 但是 $W(k)$ 与 $V(k)$ 的噪声分布不相关。

扩展卡尔曼滤波要解决的问题是, 根据第 k 时刻的观测值与给定的非线性系统的初始状态 $X(0)$ 计算求得第 k 时刻系统状态的最优估计值 $\hat{X}(k)$ 。

若式(4.20)与式(4.21)中的非线性函数足够平滑, 使用非线性函数对估计值 $\hat{X}(k)$ 求导, 略去一阶项以上的高阶项, 有

$$f(X(k)) = f(\hat{X}(k)) + F(k) \times (X(k) - \hat{X}(k)) \quad (4.22)$$

$$h(X(k)) = h(\hat{X}(k)) + H(k) \times (X(k) - \hat{X}(k)) \quad (4.23)$$

上式中,

$$F(k) = \frac{\partial f(X)}{\partial(X)} \quad (4.24)$$

$$H(k) = \frac{\partial h(X)}{\partial(X)} \quad (4.25)$$

将式(4.22)、(4.23)分别代入式(4.20)、(4.21)，有

$$X(k+1) = F(k)X(k) + W(k) + \phi(k) \quad (4.26)$$

$$Y(k) = H(k)X(k) + V(k) + \varphi(k) \quad (4.27)$$

上式中，

$$\phi(k) = f(\hat{X}(k)) - F(k)\hat{X}(k) \quad (4.28)$$

$$\varphi(k) = h(\hat{X}(k)) - H(k)\hat{X}(k) \quad (4.29)$$

第 k 时刻系统状态的最优估计值 $\hat{X}(k)$ 可由卡尔曼滤波递推方程得到

$$K(k) = P(k)H(k)^T[R + H(k)P(k)H(k)^T]^{-1} \quad (4.30)$$

$$\hat{X}(k) = f(\hat{X}(k-1)) + K(k)[Y(k) - h(\hat{X}(k-1))] \quad (4.31)$$

$$P(k+1) = F(k)[P(k) - K(k)H(k)P(k)]F(k)^T + Q \quad (4.32)$$

上式中， $K(k)$ 是卡尔曼滤波的增益矩阵， $P(k)$ 是状态估计误差的协方差矩阵， R 是观测噪声的方差， Q 是系统噪声的方差

利用扩展卡尔曼滤波调整优化模糊神经网络时，可以把模糊神经网络的前件参数视作扩展卡尔曼滤波器的输入，模糊神经网络的输出可以由扩展卡尔曼滤波的输出得到，

$$Y = [Y(1) \quad \dots \quad Y(n)]^T \quad (4.33)$$

$$h(\hat{X}(k)) = [\hat{Y}(1) \quad \dots \quad \hat{Y}(n)]^T \quad (4.34)$$

上式中， Y 为模糊神经网络的期望输出， $h(\hat{X}(k))$ 为网络训练过程中第 k 次迭代的实际输出，两者的差值即扩展卡尔曼滤波中的新息项

综上，模糊神经网络可以被建模为非线性的方程组

$$X(k+1) = X(k) + W(k) \quad (4.35)$$

$$Y(k) = h(X(k)) + V(k) \quad (4.36)$$

该方程组如果使用式(4.30)-(4.32)的扩展卡尔曼滤波算法，那么 $f(\cdot)$ 是该系统的状态转移矩阵， $Y(k)$ 是输入输出样本中的期望输出， $h(\hat{X}(k))$ 是扩展卡尔曼滤波的实际输出， $H(k)$ 是网络参数在实际输出处进行一阶泰勒展开的结果， $F(k)$ 是单位矩阵， Q 是系统噪声的方差， R 是观测噪声的方差。

4.3.3 模糊神经网络的分布式调整

使用扩展卡尔曼滤波优化与调整模糊神经网络参数时也存在一定问题，即该方法因为涉及到大量的矩阵相乘运算，导致计算量过大，在计算机中表现为内存溢出或者运算时间过长，所以需要简化方法，本章采用的手段是将整个计算过程进行解耦分为

前部与后部，前部使用扩展卡尔曼滤波解决非线性的滤波问题，后部使用卡尔曼滤波解决线性滤波问题，这样可以有效地降低计算量，提高了计算速度与内存安全性。

前部计算：使用扩展卡尔曼滤波对网络中已有的模糊化函数的宽度参数进行调整

$$K_{\sigma}(k) = P_{\sigma}(k-1)G(k)^T[R(k) + G(k)P_{\sigma}(k-1)G(k)^T]^{-1} \quad (4.37)$$

$$\sigma(k) = \sigma(k-1) + K_{\sigma}(k)(Y(k) - B(k-1)\phi(k)) \quad (4.38)$$

$$P_{\sigma}(k) = P_{\sigma}(k-1) - K_{\sigma}(k)G(k)P_{\sigma}(k-1) + Q(k) \quad (4.39)$$

上式中， $K_{\sigma}(k)$ 是扩展卡尔曼滤波的增益矩阵， $P_{\sigma}(k)$ 是预测误差的协方差矩阵，它们的下标 $\sigma(k)$ 是模糊化函数的宽度， $G(k)$ 是网络实际输出对宽度 $\sigma(k)$ 的偏导数， $R(k)$ 是观测噪声协方差， $Q(k)$ 是系统噪声协方差。

后部计算：使用卡尔曼滤波解决线性滤波问题

$$K_b(k) = P_b(k-1)\phi(k)^T[R(k) + \phi(k)P_b(k-1)\phi(k)^T]^{-1} \quad (4.40)$$

$$B(k) = B(k-1) + K_b(k)(Y(k) - B(k-1)\phi(k)) \quad (4.41)$$

$$P_b(k) = P_b(k-1) - K_b(k)\phi(k)P_b(k-1) + Q(k) \quad (4.42)$$

上式中， $K_b(k)$ 是卡尔曼滤波的增益矩阵， $P_b(k)$ 是预测误差的协方差矩阵，它们的下标 b 是网络的后部参数， $R(k)$ 是观测噪声协方差， $Q(k)$ 是系统噪声协方差。

4.3.4 模糊规则的新增加策略

网络参数初始化：在第一组输入输出样本 (X_1, t_1) 输入到输入层前，模糊神经网络并没有完整的结构，输入时为网络增加新的模糊规则 $C_1 = X_1 = [x_{11} \ \dots \ x_{r1}]^T, \sigma_1 = \sigma_0, b_1 = t_1$ ， σ_0 是预先设定的常数。

滤波迭代更新：在第 i 组输入输出样本 (X_i, t_i) 输入时，对模糊规则层的所有神经元进行运算，计算 GF

如果

$$GF < k_{GF} \quad (4.43)$$

条件被满足，那么为模糊化层添加一个新的模糊化函数，其有中心、宽度与权值

$$C_{u+1} = X_i = [x_{1i} \ \dots \ x_{ri}]^T \quad (4.44)$$

$$\sigma_{u+1} = k_0 d_{i,min} \quad (4.45)$$

$$b_{u+1} = e_i \quad (4.46)$$

上式中， k_0 是重叠因子， $d_{i,min}$ 是模糊化函数的最小长度， e_i 是实际输出与期望输出的表观误差。

网络参数学习：使用式(4.37)-(4.42)所述算法调整包含新增模糊化函数的网络全部模糊化函数。

4.4 仿真实验

将目光聚焦于钱塘江，规范合理地提取水体样本，基于此对钱塘江水质情况作出科学合理地评估，采样取水口为杭州市钱塘江上游富阳水厂、中游玉龙水厂和下游九溪水厂，采样时间为2003年-2008年，在此期间，每隔三个月采样一次，主要涉及到

总磷含量、氨氮含量等多个重要指标。

通过本章构建的基于 T-S 模糊神经网络科学合理地分析水样，根据分析结果对钱塘江水质等级进行客观全面地判定。第一步，应结合训练样本输入/输出维数的多少，科学合理地设置模糊神经网络的输入/输出节点数，由于输入数据为采样水体六项指标的归一化，获得的输出数据信息即指的是基于网络评估值而获取的水质等级指标，若网络评估值未超过 1.5，那么可将水质等级指标判定为 1 级，若网络评估值介于 1.5~2.5 之间，那么可将水质判定为 2 级，若网络评估值介于 2.5~3.5 之间，那么可将水质判定为 3 级，若网络评估值介于 3.5~4.5，那么可将水质判定为 4 级，若网络评估值超过 4.5，那么可将水质判定为 5 级。因此，基于训练样本的输入/输出维数将模糊神经网络的输入/输出节点数量分别取 6、1，模糊化函数的数量取 12，基于此构建了结构体系为 6-12-1、严谨规范、科学合理的模糊神经网络，使用 MATLAB 内置随机函数初始化模糊系统的模糊隶属度函数系数 $p_0 \sim p_6$ 、宽度 σ 和中心 c 。

鉴于水质评价的实际信息无法容易快速的获取，因此，本章决定通过当前应用比较广泛的内插法选取合适的训练样本，模糊神经网络在应用过程中，对训练数据训练百次，关于水质指标标准信息可参考下表：

表 4.1 水质等级指标分类

分类	I类	II类	III类	IV类	V类
$\text{NH}_3/(\text{mg} \cdot \text{L}^{-1}) \leq$	0.15	0.50	1.0	1.5	2.0
$\text{DO}/(\text{mg} \cdot \text{L}^{-1}) \leq$	7.5	6.0	5.0	3.0	2.0
$\text{COD}/(\text{mg} \cdot \text{L}^{-1}) \leq$	15	15	20	30	40
$\text{KMnO}_4/(\text{mg} \cdot \text{L}^{-1}) \leq$	2.0	4.0	6.0	10	15
$\text{TP}/(\text{mg} \cdot \text{L}^{-1}) \leq$	0.02	0.10	0.20	0.30	0.40
$\text{TN}/(\text{mg} \cdot \text{L}^{-1}) \leq$	0.20	0.50	1.0	1.5	2.0

模糊神经网络的预测机制简单来讲指的是通过按照相关标准或者要求训练完成的模糊神经网络对样本等级进行科学合理地判定。主要涉及到下述几个步骤：第一，根据训练输入/输出数据维数的多少，构建准确可靠且符合要求的网络结构体系；第二，对模糊神经网络隶属度函数参数以及系数实施初始化处理，同时需要对获取到的各种训练数据进行规范合理地归一化处理；第三，通过已选取好的训练样本专业规范地训练模糊神经网络；第四，通过已训练完成且严谨完善的模糊神经网络客观全面地评估钱塘江水质，最后结合网络评估值对水质等级进行准确合理地判定。

现用扩展卡尔曼滤波优化模糊神经网络非线性前件，卡尔曼滤波优化网络线性后件，在网络训练过程中持续优化网络参数，拟获得更优的水质等级指标识别率。

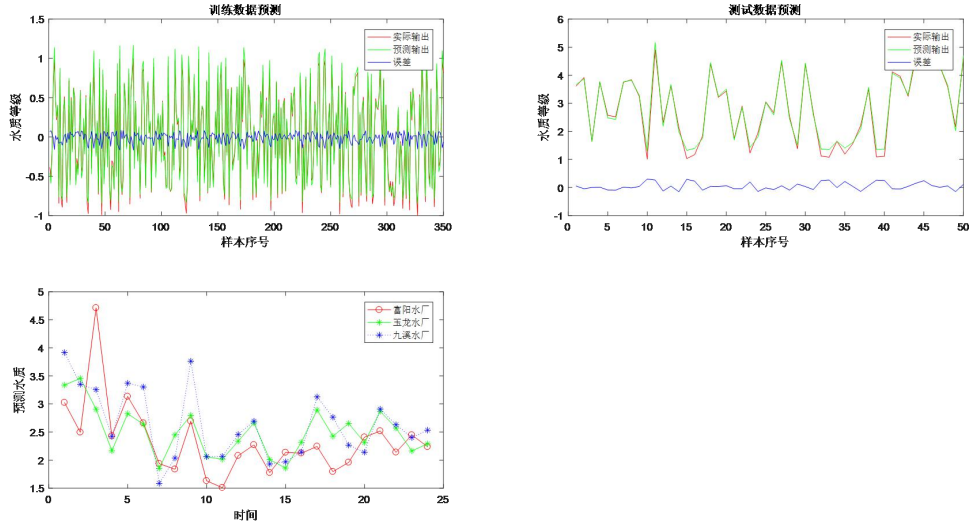


图 4.1 优化前网络预测结果

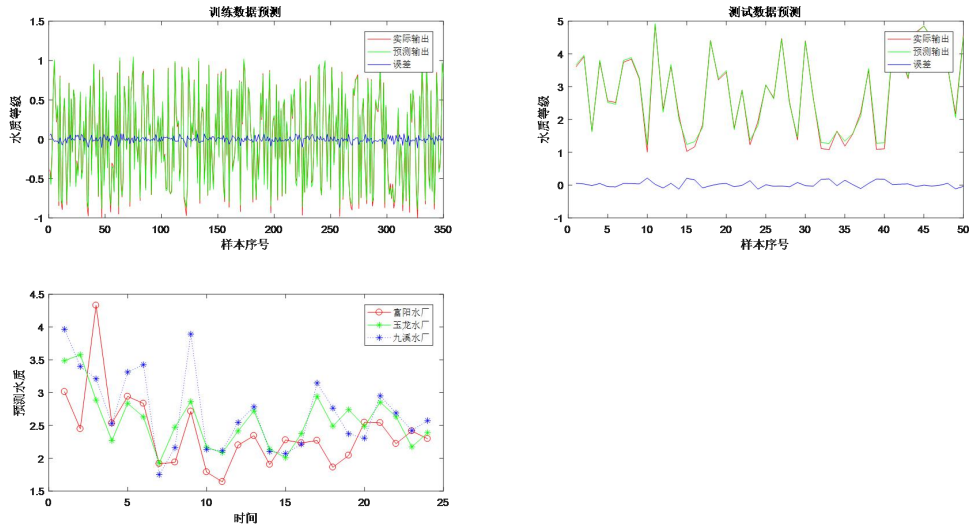


图 4.2 优化后网络预测结果

表 4.2 优化前后网络预测的均方根误差

算法	训练均方根误差	测试均方根误差
模糊神经网络	0.0842	0.1967
滤波优化的模糊神经网络	0.0486	0.1143

通过训练数据样本训练模糊神经网络百次，通过训练完成的神经网络科学合理地预测训练数据样本、测试数据样本与 2003 年~2008 年的采样数据样本，对比结果如图 4.1。现用扩展卡尔曼滤波优化模糊神经网络非线性前件，卡尔曼滤波优化网络线性后件，在网络训练过程中持续优化网络参数，通过训练完成的神经网络科学合理地预测训练数据样本、测试数据样本与 2003 年~2008 年的采样数据样本对比结果如图 4.2。表 4.2 里，卡尔曼滤波器优化后的模糊神经网络相较模糊神经网络的预测结果有更低

的均方根误差，表明了优化后的网络获得了更优的水质等级指标识别率。

4.5 总结与分析

本章针对环境工程中水质评价的问题提出了人工智能解决方案，构建了一个分布式神经网络，该网络由前置的卷积神经网络与后置的模糊神经网络构建而成，前置的卷积神经网络通过输入采样水的数字图像，输出采样水的各项水体水质的分析指标；后置的模糊神经网络通过输入采样水的各项水体水质的分析指标，输出采样水样本的水质等级。本章做的工作是利用卡尔曼滤波器建模优化参数的特性，对分布式神经网络后置的模糊神经网络进行参数优化。对网络包含非线性特性的前件予以扩展卡尔曼滤波处理，而包含线性特性的后件则实施卡尔曼滤波。仿真实验中对通过构建的训练样本进行网络参数训练，结果在进行卡尔曼滤波器优化处理后，模糊神经网络变得更加完善合理，不仅训练样本预测的均方根误差明显变小，测试样本预测的均方根误差也相较之前大幅降低，说明模糊神经网络在水质评价的问题上能通过卡尔曼滤波器的优化得到更优秀的水质等级指标识别率。

本章也存在不足，即以模糊神经网络为支撑的卡尔曼滤波方法，未能对前置的卷积神经网络给出详细具体的改进方案。鉴于对水质评价过程中，无法获取大量的实际样本的局限性，本方法仅是在实际获得的少量样本基础上，利用内插法进行了样本扩容，来实现对网络参数的训练。

第 5 章 基于线性回归人脸识别的卡尔曼滤波方法

5.1 引言

中国人口规模庞大,现已达到了 14 亿人之多,如何高效高质地管理人口是当前亟待解决的重要问题。目前,在人口管理方面,身份识别发挥着极其重要的作用,特别是人脸识别,为人口 c 管理工作的顺利开展提供了强大支持^[26]。相较于虹膜等生物信息而言,人脸更加友好与便捷,并且一般不会对用户的心理造成不良影响,因此其具有广阔的前景,常广泛应用于电脑、手机、门禁等终端设备^[27]。

人脸识别是近些年炙手可热的研究方向,国内外许多大学、研究所与 IT 公司对人脸识别进行了深入的研究,并取得了令人瞩目的成果。压缩感知在数学领域占据着举足轻重的地位,基于压缩感知的识别技术也日臻成熟,凭借着独特的优势在机器学习、模式识别等多个不同领域得到了广泛的应用^[28]。流形学习是一个比较宽泛的概念,主要涉及到几何等相关学科,可利用降维的方式获得嵌入至高维空间的低维流形,而这即是人类认知行为得以存在和发展的重要前提,与人类的认知过程非常一致,将其灵活合理地应用于模式识别领域,并且将其和现实问题进行密切融合,实践价值较为突出^[29]。基于深度识别的面部识别技术也是近些年的热门技术,它依赖于神经网络、图论与概率论等多门学科,在解决实际问题方面表现出了巨大潜力,成为学术界与工程学中广受关注的一门学科^[30]。

一个 $a \times b$ 阶的灰度面部图像在原始图像空间中可通过 $a \times b$ 维的向量的形式进行展示,不考虑维数灾难,即需要通过特征提取将高维向量转化为低维向量的问题,多个不同个体面部的向量可以通过列连接构成一个分类模型,并根据不同个体配置对应的标签向量。当新的未标记的面部图像需要被识别出是标签向量中的哪个个体时,可将其同样转化为列向量,并表示为分类模型的线性组合,该线性组合的参数向量,即分类模型中不同个体面部向量重构待识别面部向量的权重,权重越高,待识别个体是该面部向量对应个体的概率越大,这是一种比较经典且成熟的以线性回归为基础的人脸识别方法^[31]。本章在借鉴前人研究成果的基础上通过深入细致地分析,提出了一种以线性回归人脸识别为支撑的卡尔曼滤波方法,将待识别面部图像 $a \times b$ 维的列向量形式作为观测值,分 b 次输入,分类模型作为观测矩阵,迭代更新估计分类模型线性表示待识别列向量的参数向量。该方法经过迭代更新参数向量,可以获得更高的人脸识别正确率,并且具有解决维数问题的潜能。

本章的主要研究思想与研究方案是:提出基于线性回归人脸识别的卡尔曼滤波方法,阐述基于线性回归的人脸识别方法,通过卡尔曼滤波器分次输入线性回归的参数,最优估计分类模型重构待识别人脸的权重,无需常规的图像特征提取流程,依然能够获得可观的人脸识别正确率,将该方法用于抑制噪声的图像增强,可以有效提高人脸

识别的精度。

本章安排如下，第 5.2 节对人脸识别问题进行建模，对以线性回归为支撑的人脸识别方法进行了详细全面地论述，第 5.3 节对分类模型通过线性回归进行人脸识别的方法，进行卡尔曼滤波方程组的建模，同时对以线性回归人脸识别为支撑的卡尔曼滤波方法，进行了清晰简单地说明，第 5.4 节对为非限制场景下的人脸识别经典数据集 The Japanese Female Facial Expression(JAFFE) Database 进行数据仿真实验，将进行基于线性回归的人脸识别方法与经过卡尔曼滤波器优化后的方法进行定性与定量的分析对比，以此验证滤波优化的有效性。

5.2 基于线性回归的人脸识别方法

假设有 N 个可区别的类，每个类各取一个角度较正、清晰度好的面部图像作为分类训练图，每个分类训练图灰度具有 $a \times b$ 阶，表示为 $w_i \in R^{a \times b}; i = 1, 2, \dots, N$ 。不考虑特征提取与矩阵降维，每个分类训练图通过列连接 $w_i \in R^{a \times b} \rightarrow p_i \in R^{c \times 1}$ ，其中 $c = ab$ 。每个图像向量被标准化，使得最大像素值为 1。通过堆叠 N 个可区别类的 c 维图像向量，可以构建一个分类模型 P

$$P = [p_1 \quad \dots \quad p_N] \in R^{c \times N} \quad (5.1)$$

这 N 个可区别类的图像向量都可用分类模型 P 线性表示，也称作类的向量回归与预测。该分类模型用于人脸识别根据可区别的类，配置对应的标签向量 K

$$K = [k_1 \quad \dots \quad k_N] \in R^{1 \times N} \quad (5.2)$$

其中，值 k_1 为图像向量 p_1 对应类的标签，用于回归向量区分类个体。

将 z 定义为未进行任何标记的测试图像，准确高效地辨识出 z 为类 $i = 1, 2, \dots, N$ 中的具体哪一类。将灰度图像进行科学合理地转换，然后对其进行相应地标准化处理，促其演变为如下图像向量 $y \in R^{c \times 1}$ 。将 y 定义为分类模型 P 的线性组合

$$y = P\beta \quad (5.3)$$

上式中， $\beta \in R^{N \times 1}$ 为分类模型 P 对未标记类图像向量 y 的回归向量。

$$\beta = [\alpha_1 \quad \dots \quad \alpha_N] \quad (5.4)$$

其中， α_1 到 α_N 是分类模型 P 中 N 个可区别类的图像向量重构未标记类图像向量 y 的权重。权重 α_i 越大，未标记类图像向量 y 的原型 z 标记为 k_i 的概率越大，根据最大重构权重 α_i 可以识别原型 z 为标签向量 k_i 对应的类个体。

5.3 基于线性回归人脸识别的卡尔曼滤波方法

5.3.1 卡尔曼滤波方法建模

因为需要使用卡尔曼滤波器，迭代更新分类模型的图像向量重构未标记类图像向量的权重，所以需要对上述分类模型 P 的线性回归过程进行数学建模。

$$X(k+1) = AX(k) + W(k), k = 0, 1, 2, \dots, b \quad (5.5)$$

上式中, $X(k)$ 是分类模型 P 对未标记类图像第 k 列的回归向量, A 是单位矩阵, $W(k)$ 是预设的系统噪声。

有观测矩阵

$$Y(k) = H(k)X(k) + V(k), k = 1, 2, \dots, b \quad (5.6)$$

上式中, $Y(k)$ 是未标记图像的第 k 列, $H(k)$ 是分类模型中所有图像向量的第 k 列组成的矩阵, $V(k)$ 是预设的观测噪声。




图 5.1 卡尔曼滤波方法图

5.3.2 卡尔曼滤波方法描述

基于线性回归人脸识别的卡尔曼滤波方法, 需预先设定回归向量的初始估计值 $\hat{X}(0)$ 和初始估计协方差矩阵 $P(0)$, 其核心思想主要是基于前 k 个输入的未标记图像部分向量计算, 得到回归向量第 k 次迭代的最优估计值

$$\hat{X}(k|k) = E\{X(k)|\hat{X}(0), Y(1), \dots, Y(k)\} \quad (5.7)$$

与估计协方差矩阵

$$P(k|k) = E\{[X(k) - \hat{X}(k|k)][X(k) - \hat{X}(k|k)]^T\} \quad (5.8)$$

首先进行卡尔曼滤波器对状态估计值、状态估计值误差协方差矩阵与测量值的一步预测。根据状态转移矩阵 A 与回归向量的最优估计值 $\hat{X}(k|k)$, 得到卡尔曼滤波器对本次迭代更新的状态最优估计值的一步预测 $\hat{X}(k+1|k)$

$$\hat{X}(k+1|k) = E\{X(k+1)|\hat{X}(0), Y(1), \dots, Y(k)\} = A\hat{X}(k|k) \quad (5.9)$$

根据状态转移矩阵 A 、估计协方差矩阵 $P(k|k)$ 和预设的系统噪声方差 Q , 得到卡尔曼滤波器对本次迭代更新的状态估计值误差协方差矩阵的一步预测 $P(k+1|k)$

$$P(k+1|k) = E\{[X(k+1) - \hat{X}(k+1|k)][X(k+1) - \hat{X}(k+1|k)]^T\} = AP(k|k)A^T + Q \quad (5.10)$$

根据分类模型中所有图像向量的第 $k+1$ 列组成的矩阵 $H(k+1)$ 与状态最优估计值的一步预测 $\hat{X}(k+1|k)$ ，得到卡尔曼滤波器对本次迭代更新的测量值的一步预测 $\hat{Y}(k+1|k)$

$$\hat{Y}(k+1|k) = H(k+1)\hat{X}(k+1|k) \quad (5.11)$$

然后根据状态估计值误差协方差矩阵的一步预测 $P(k+1|k)$ 、分类模型中所有图像向量的第 $k+1$ 列组成的矩阵 $H(k+1)$ 和预设的观测噪声方差 R ，计算本次迭代更新中观测值一步预测 $\hat{Y}(k+1|k)$ 与状态最优估计值一步预测 $\hat{X}(k+1|k)$ 的加权比例，即最优增益阵 $K(k+1)$

$$K(k+1) = P(k+1|k)H(k+1)^T[H(k+1)P(k+1|k)H(k+1)^T + R]^{-1} \quad (5.12)$$

再通过状态最优估计值一步预测 $\hat{X}(k+1|k)$ 、未标记图像的第 k 列与观测值一步预测 $\hat{Y}(k+1|k)$ 的差值即新息，根据最优增益阵加权融合，得到回归向量第 $k+1$ 次迭代的最优估计值 $\hat{X}(k+1|k+1)$ 与最优估计协方差矩阵 $P(k+1|k+1)$

$$\hat{X}(k+1|k+1) = \hat{X}(k+1|k) + K(k+1)[Y(k+1) - \hat{Y}(k+1|k)] \quad (5.13)$$

$$P(k+1|k+1) = [I - K(k+1)H(k+1)]P(k+1|k) \quad (5.14)$$

上式中， $I = \begin{bmatrix} 1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 1 \end{bmatrix}$ 。

最后基于前 k 个输入的未标记图像部分向量 $Y(1)$ 、 $Y(2)$ ，...， $Y(N)$ ，可得到回归向量第 k 次迭代的最优估计值

$$\hat{X}(N|N) = E\{X|Y(1),...,Y(k),...,Y(b)\} \quad (5.15)$$

基于线性回归人脸识别的卡尔曼滤波方法步骤总结如下

步骤 1：流程初始化

(1) 已知回归向量的初始估计值 $\hat{X}(0)$ 与预设的初始估计协方差矩阵 $P(0)$ 。

(2) 基于(5.7)和(5.8)预设的第 k 次迭代的回归向量最优估计值和相应的估计协方差矩阵 $P(k|k)$ 。

步骤 2：根据步骤 1 得到一步预测结果

(1) 基于(5.9)的状态估计值一步预测 $\hat{X}(k+1|k)$ 。

(2) 基于(5.10)的状态估计值误差协方差矩阵一步预测 $P(k+1|k)$ 。

(3) 基于(5.11)测量值一步预测 $\hat{Y}(k+1|k)$ 。

步骤 3：根据(5.12)计算卡尔曼滤波增益阵 $K(k+1)$ 。

步骤 4：状态估计实时更新：根据(5.13)的状态估计值更新 $\hat{X}(k+1|k+1)$ 和根据(5.14)的状态估计误差协方差矩阵更新 $P(k+1|k+1)$ 。

步骤 5：返回步骤 2，重复步骤 2~4 直到未标记图像向量所有部分输入完毕，即 $k = 1, 2, \dots, b$ 。

步骤 6：得到基于线性回归人脸识别的卡尔曼滤波方法结果即(5.15)中 $\hat{X}(N|N)$ 。

5.4 仿真实验

仿真分析过程中选取的数据集是各种场合下的人脸识别经典数据集(JAFFE)。它主要包含了 10 个人的 213 张图像，一人为一组，每组均包括 7 种表情，每种表情用 3~4 张样图进行显示。

现选取 10 个人角度校正、清晰度好的一张图像作为分类训练图，10 张图像分别进行图像预处理：缩小至 256×256 像素，进行标准灰度转化，通过列连接构建成 65536×1 维的图像向量。堆叠这 10 个列向量构建成 65536×10 维的分类模型，并配置相应的标签向量以此对剩余 203 张图像进行人脸识别。对剩余 203 张图像进行上述同样的预处理，则有 203 个 65536×1 维的图像向量作为测试集，并配置相应的标签向量。分别使用基于线性回归的人脸识别方法与基于线性回归人脸识别的卡尔曼滤波方法对 203 张测试样本的任 50 张进行人脸识别分类，并与相应的标签进行正确率比对。因为配置了测试集的标签向量，所以可以观测到正确匹配项的重构权重变化。

给定卡尔曼滤波器初始条件 $\hat{X}(0)$ 为 1×10 维的初始回归向量，其中各回归重构权重初始值为 0，A 为 10×10 的单位矩阵，给定 $P(0)$ 、 Q 、 R 分别为

$$P(0) = \begin{bmatrix} 1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 1 \end{bmatrix} \times 0.01 \in R^{10 \times 10} \quad (5.16)$$

$$Q = \begin{bmatrix} 1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 1 \end{bmatrix} \times 10^{-10} \in R^{10 \times 10} \quad (5.17)$$

$$R = \begin{bmatrix} 1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 1 \end{bmatrix} \times 10 \in R^{256 \times 256} \quad (5.18)$$

仿真实验结果如下

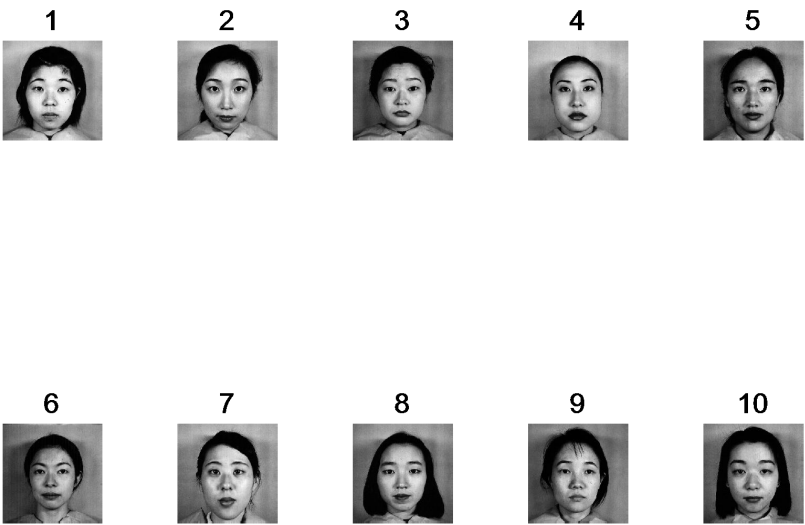


图 5.1 分类训练图

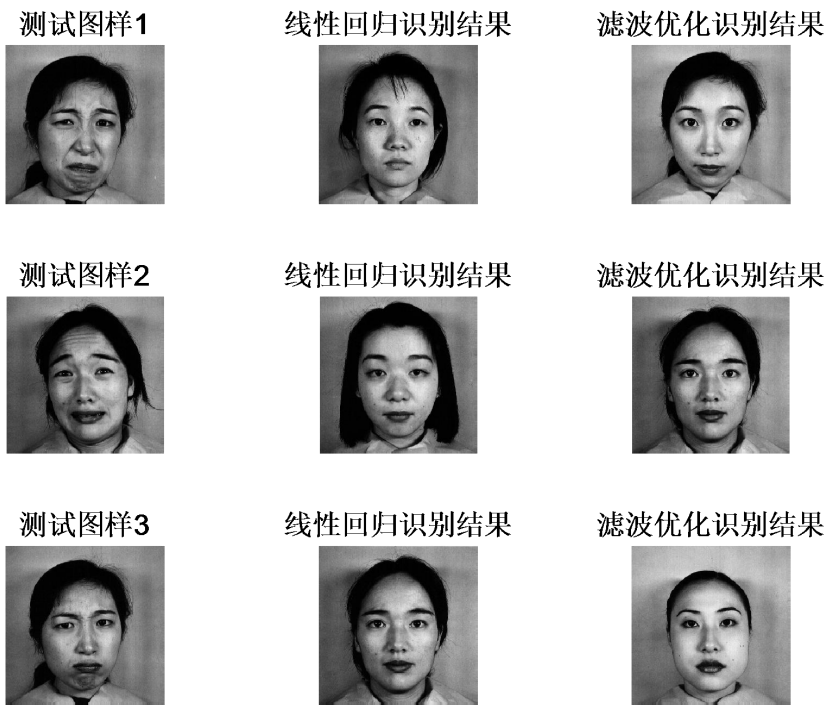


图 5.2 部分识别错误图样




图 5.3 某次识别中正确匹配项的重构权重

表 5.1 滤波优化前后方法人脸识别正确率

算法	正确率
基于线性回归的人脸识别	90%
滤波优化的线性回归	92%

图 5.1 为构成分类模型的 10 张分类训练图，并且根据分类进行编号构建了标签向量。图 5.2 为测试图样人脸识别错误的部分样例，以线性回归为基础的人脸识别方法对测试图样 1、2、3 识别的结果错误，滤波优化后的线性回归对测试图样 1、2 的识别结果正确，表 5.1 为滤波优化前后方法人脸识别正确率。图 5.3 中是最后一张测试图样的滤波优化线性回归方法里正确匹配项的重构权重，可以看出随着输入列数的增加，正确匹配项的重构权重稳定提升，最后也能得到正确的识别分类结果。

值得一提的是，滤波优化的线性回归方法如果在达到一定阈值时就确定分类结果，就可以提高线性回归的速度，如果引入图像增强或图像压缩，则具有快速人脸识别的潜力。

5.5 总结与分析

针对模式识别中热门的人脸识别问题，本章提出了基于线性回归的人脸识别方法，并且使用卡尔曼滤波器可以优化参数估计的特性，对基于线性回归的人脸识别方法进行数学建模，利用卡尔曼滤波器迭代优化线性回归的回归向量，即分类模型重构测试图样的权重，可得到更优的人脸识别正确率。仿真实验中对于非限制场景下的人脸识

别经典数据集 JAFFE Database 取相同的分类模型与测试图样，滤波优化后的线性回归方法比基于线性回归的人脸识别方法有更好的人脸识别正确率，并且因为预先配置了对应的训练集与测试集的标签向量，所以可以观察到滤波优化后线性回归方法里最后一次识别的正确匹配项的权重变化，该权重呈稳定提升的趋势，最后也能得到正确的人脸识别分类结果。值得一提的是，滤波优化的线性回归方法如果在达到一定阈值时就确定分类结果，就可以提高线性回归的速度，如果引入图像增强或图像压缩，则具有快速人脸识别的潜力。

本章也存在不足，即没有对上面提出的达到一定阈值时就确定分类结果的问题进行深入探讨，没有引入图像增强或图像压缩，没有构建一个完整的卡尔曼滤波优化的基于线性回归快速人脸识别系统，因此本章对接下来的工作做准备。

第6章 总结与展望

6.1 工作总结

本文叙述了图像处理的发展轨迹、数字图像处理的常见手段、数字图像滤波的意义及卡尔曼滤波作为数字图像滤波的常用算法并对卡尔曼滤波在工程领域应用潜力进行探讨，主要成果有：

1) 针对一个运动目标，传感器持续跟踪获得其受噪声干扰、形变影响的序列观测图像，由此提出了基于大数定律的序列图像融合方法与基于卡尔曼滤波的图像恢复方法，进而将方法应用于处理不同场景下的序列观测图像。实验结果表明：在序列观测图像中每幅图像所含高斯白噪声方差相同的场景下，基于大数定律序列图像融合方法能够通过融合序列观测图像得到比其他滤波方法更好的去噪效果以估计原始图像。在序列观测图像中每幅图像所含高斯白噪声方差各不相同的场景下，基于卡尔曼滤波的图像恢复方法相比其他方法有更好的定量评价指标。在序列观测图像中每幅图像持续形变且所含高斯白噪声方差各不相同的场景下，基于大数定律序列图像融合方法失效，而基于卡尔曼滤波的图像恢复方法仍然可以通过融合序列图像以重构原始图像。

2) 针对环境工程中水质评价的问题提出了人工智能解决方案，构建了一个分布式神经网络由前置的卷积神经网络与后置的模糊神经网络构建而成，前置的卷积神经网络通过输入采样水的数字图像，输出采样水的各项水体水质的分析指标；后置的模糊神经网络通过输入采样水的各项水体水质的分析指标，输出采样水样本的水质等级。本章做的工作是利用卡尔曼滤波器建模优化参数的特性，对分布式神经网络后置的模糊神经网络进行网络参数优化。对网络包含非线性特性的前件予以扩展卡尔曼滤波处理，而包含线性特性的后件则实施卡尔曼滤波。仿真实验中对通过构建的训练样本进行网络参数训练，结果在进行卡尔曼滤波器优化处理后，模糊神经网络变得更加完善合理，不仅训练样本预测的均方根误差明显变小，测试样本预测的均方根误差也相较之前大幅降低，说明模糊神经网络在水质评价的问题上能通过卡尔曼滤波器的优化得到更优秀的水质等级指标识别率。

3) 针对模式识别中热门的人脸识别问题，提出了基于线性回归的人脸识别方法，并且使用卡尔曼滤波器可以优化参数估计的特性，对基于线性回归的人脸识别方法进行数学建模，利用卡尔曼滤波器迭代优化线性回归的回归向量即分类模型重构测试图样的权重，可得到更优的人脸识别正确率。仿真实验中对于非限制场景下的人脸识别经典数据集 JAFFE Database 取相同的分类模型与测试图样，滤波优化后的线性回归方法比基于线性回归的人脸识别方法有更好的人脸识别正确率，并且因为预先配置了对应的训练集与测试集的标签向量，所以可以观察到滤波优化后线性回归方法里最后一次识别的正确匹配项的权重，该权重呈稳定提升的趋势，最后也能得到正确的人脸

识别分类结果。值得一提的是，滤波优化的线性回归方法如果在达到一定阈值时就确定分类结果，就可以提高线性回归的速度，如果引入图像增强或图像压缩，则具有快速人脸识别的潜力。

6.2 未来展望

1) 基于序列跟踪目标图像恢复的卡尔曼滤波方法存在一定的局限性，即该方法只能对发生线性变换的受损图像集进行恢复。当受损图像集发生非线性变换时，需要引入图像拓扑变换且使用非线性滤波器才可以解决问题，因此基于序列跟踪目标图像恢复的卡尔曼滤波方法的研究与提出可以为今后的工作做准备。

2) 对基于神经网络水样图像水质评价的卡尔曼滤波方法研究的不足主要有两点，其一是只针对分布式神经网络后置的模糊神经网络进行了参数优化，未能对前置的卷积神经网络给出详细具体的改进方案。其二是在模糊神经网络的训练过程中，由于无法获取大量实际的样本，所以仅是利用内插法对少量实际的样本进行了样本扩容，以此进行网络参数的训练。

3) 基于线性回归人脸识别的卡尔曼滤波方法具有两点可以深入研究，其一是提出的方法中引入图像增强或图像压缩，拟可提高识别的正确率。其二是各个重构权重或其差值达到预设的阈值时就确定分类结果，拟可提升识别的速度。如上两点结合可以实现一个更佳的卡尔曼滤波优化的基于线性回归的人脸识别系统，因此基于线性回归人脸识别的卡尔曼滤波方法的研究与提出为接下来的工作奠定了基石。

致 谢

不知不觉又到了毕业季节，回首两余载的研究生生涯，根据老师的指点进行了很多科研性工作，也与朋友一起完成了自己的创作性成果。在这样一个庞大又温馨的家庭中，仅仅两年半的愉快生活与专心工作，使我拥有了我一生中最难以忘怀的经历。我可以预见到这将是一笔巨大的精神财富，使我在接下来的工作与生活中可以迅速成长，敢于直面生活与工作的挑战与困境。我要郑重感谢在过去的两年半中我的老师和同学与我愉快的合作，和我身陷囹圄时向我伸出的援手。

首先，要对导师质疑诚挚的谢意，老师在治学过程中所表现出来的严谨端正的学术作风、平易近人的做人态度等均给予了我很大启迪，在今后，我定以老师为榜样，将其作为我前行之路的启明灯，感谢从我入学时的零基础开始到毕业论文完成后的耐心教学。实验室的周一到周末总是可以看到老师辛勤的身影，聚餐时的酒桌上老师又可以与我们把酒言欢，这种工作态度与为人处世教会我的不仅仅是知识，而是更加宝贵的人生经验。今后，我会将实验室里面对科学研究的严谨态度带入到接下来的工作中去，我会以积极的眼光与勇敢的态度面对接下来的全新挑战。在此诚挚地祝愿您健康平安、万事如意。

其实，还要感谢自动化院控制工程专业系统建模与信息处理实验室这个庞大又温馨的家庭给我提供的舒适又优质的学习环境。在系统建模与信息处理实验室里，每个人都全身心投入到科学研究，并且从心底里热爱科学研究的事业。实验室里广泛的科学研究主题与方向可以供每个人根据自己的专业知识与兴趣进行选择。实验室的考勤系统也提高了大家的科研热情，每天的大部分时间都被有效地利用在了科研上。同时，实验室还开展了各种丰富有趣的活动，例如实验室的运动会与自助烤肉的春游。统建模与信息处理实验室这个庞大又温馨的家庭给我带来的不仅仅是科学研究与学习中所获得的知识，更是日常生活中精神层面的满足感。同时，在过去的两年半研究生生活中，我从许多同学那里学到了许多很好的品质，感谢。

在此，特别感谢，老师的同门们组成了学习小组，大家一起学习、讨论问题并且相互扶持，有了他们的陪伴，在系统建模与信息处理实验室两年半的工作十分充实。

最后，还要向一直以来默默付出并给予我无私支持和帮助的父母致以诚挚的谢意，你们是我前行之路最坚实的后盾，在此向你们表达我诚挚的谢意，专注于科研工作和勇敢地面对接下来的生活是我给他们的最好的礼物。

在未来的日子里，生活肯定不会一帆风顺，各种挫折与失败都可能发生，但是高尔基说过“人只能被消灭，不会被打败”，我亦是如此。在杭州电子科技大学的磨砺与锻炼令我受益匪浅，感谢所有帮助我的人。秉持着这一信念，我将勇敢面对更加艰难的未来。

参考文献

- [1] 陈大力. 数字图像处理中去噪算法的研究[D].东北大学,2008.
- [2] 杨昊. 图像去噪中几种优化算法的相关研究[D].电子科技大学,2016.
- [3] 李红俊,韩冀皖. 数字图像处理技术及其应用[J]. 计算机自动测量与控制, 2002(09):620-622.
- [4] Preiss Jens,Fernandes Felipe,Urban Philipp. Color-image quality assessment: from prediction to optimization.[J]. IEEE transactions on image processing : a publication of the IEEE Signal Processing Society,2014,23(3).
- [5] Gonzalez R, Woods R. Digital image processing. 电子工业出版社, 2010
- [6] 沈岨,李舜酩,毛建国,辛江慧.数字图像复原技术综述[J].中国图象图形学报, 2009, 14(09): 1764-1775.
- [7] Meinhold R J, Singpurwalla N D. Robustification of Kalman filter models [J]. Journal of the American Statistical Association. 1989, 84(406): 479-486.
- [8] Arasaratnam I, Haykin S. Square-root quadrature Kalman filtering [J]. IEEE Trans on Signal Processing. 2008, 56(6):2589-2593.
- [9] An ZHANG,Shuida BAO,Fei GAO,Wenhao BI. A novel strong tracking cubature Kalman filter and its application in maneuvering target tracking[J]. Chinese Journal of Aeronautics,2019.
- [10] Arasaratnam I, Haykin S. Cubature Kalman filters [J]. IEEE Trans on Automatic Control. 2009, 54(6):1254-1269.
- [11] 朱金华,李玉仙. 基于卡尔曼滤波的图像降噪算法 [J]. 现代电子技术,2017,40(09):22-24+28.
- [12] 荣传振,贾永兴,杨宇,朱莹,王渊.增强融合图像视觉效果的图像融合方法[J].信号处理, 2019, 35(03):327-333.
- [13] 石翠萍,韩崇彬,邓强强,陈洋.基于图形小波变换的遥感图像表示与去噪[J].电讯技术, 2020, 60(01):76-80.
- [14] 黄冬梅,戴亮,魏立斐,魏泉苗,吴国健.一种安全的多帧遥感图像的外包融合去噪方案[J].计算机研究与发展,2017,54(10):2378-2389.
- [15] 董明堃,蒋爱民,孙娟.基于字典学习的残差信息融合图像去噪方法[J].微处理机, 2015, 36(01): 58-62.
- [16] 张雪峰,闫慧.基于中值滤波和分数阶滤波的图像去噪与增强算法[J].东北大学学报(自然科学版),2020,41(04):482-487.

- [17] 冯相辉.一种改进的同态滤波图像增强算法[J].重庆邮电大学学报(自然科学版), 2020, 32(01):138-145.
- [18] Kang Kyungmo, Kim Taeyeon, Shin Cheol Woong, Kim Kichul, Kim Jiwoong, Lee Yun Gyu. Filtration efficiency and ventilation performance of window screen filters[J]. Building and Environment, 2020(prepublish).
- [19] P. Yugander, C.H. Tejaswini, J. Meenakshi, K. Samapath kumar, B.V.N. Suresh Varma, M. Jagannath. MR Image Enhancement using Adaptive Weighted Mean Filtering and Homomorphic Filtering[J]. Procedia Computer Science, 2020, 167.
- [20] Anil Kumar Pandey, Yashwariya Santosh, Param D. Sharma, Divya Yadav, Chandrashekhar Bal, Rakesh Kumar. Restoration of I-131 whole body image using a Wiener filter[J]. Nuclear Medicine Communications, 2020.
- [21] Wiener N. The extrapolation, interpolation and smooth of stationary time series[M]. OSRD70, Report to the Services 19, research project DIC-6037, MIT, 1942.
- [22] 刘玲花, 吴雷祥, 吴佳鹏, 刘来胜, 霍炜洁. 国外地表水水质指数评价法综述[J]. 水资源保护, 2016, 32(01):86-90+96.
- [23] 姜明岑, 王业耀, 姚志鹏, 刘廷良, 孙宗光, 杨琦. 地表水环境质量综合评价方法研究与应用进展[J]. 中国环境监测, 2016, 32(04):1-6.
- [24] 朱红霞, 沈炯, 苏志刚. 基于模糊观测数据的 RBF 神经网络回归模型(英文)[J]. Journal of Southeast University(English Edition), 2013, 29(04):400-406.
- [25] Novel Data and Neural Network-Based Nonlinear Adaptive Switching Control Method.[J]. IEEE transactions on neural networks and learning systems, 2020, PP.
- [26] 梁路宏, 艾海舟, 徐光祐, 张钺. 人脸检测研究综述[J]. 计算机学报, 2002(05):449-458.
- [27] 张翠平, 苏光大. 人脸识别技术综述[J]. 中国图象图形学报, 2000(11):7-16.
- [28] 周凯, 元昌安, 覃晓, 郑彦, 冯文铎. 基于核贝叶斯压缩感知的人脸识别[J]. 山东大学学报(工学版), 2016, 46(03):74-78.
- [29] 刘宇琦, 赵宏伟, 王玉. 一种基于 QPSO 优化的流形学习的视频人脸识别算法[J]. 自动化学报, 2020, 46(02):256-263.
- [30] 龚锐, 丁胜, 章超华, 苏浩. 基于深度学习的轻量级和多姿态人脸识别方法[J]. 计算机应用, 2020, 40(03):704-709.
- [31] 易月娥, 宋娟. 线性回归分析在人脸识别中的应用研究[J]. 科学技术与工程, 2013, 13(17): 4994-4998.

附 录

作者在读期间的科研成果及参加的科研项目

论文成果

- [1] 基于序列跟踪目标图像恢复的卡尔曼滤波方法（审稿中）
- [2] Sequential Kalman Filtering Method For Multi-sensor Sequential Image Restoration（审稿中）

专利成果

- 1. 文成林，付仁杰。基于卡尔曼滤波的目标序列跟踪图像恢复方法。（公开号：CN 111612729 A）

参与的科研项目

- 1. 国家自然科学基金项目：大型船舶动力系统运营全寿命周期故障预测与智能健康管理(U1509203)，200万，2016.01-2019.12；
- 2. 国家电网公司总部科技项目：大型交直流混联电网故障特征深度学习及智能识别和控制应用研究(SGHB0000KXJS1800375)，70万，2018.6-2020.12；